UNIVERSIDADE DO ESTADO DO AMAZONAS – UEA
ESCOLA SUPERIOR DE TECNOLOGIA – EST
CURSO DE BACHARELADO EM SISTEMAS DE INFORMAÇÃO

JOÃO LUCAS NORONHA DE CASTRO

AVALIAÇÃO DE MODELOS DE LINGUAGEM DE GRANDE ESCALA NA GERAÇÃO DINÂMICA DE DIÁLOGOS PARA PERSONAGENS NÃO JOGÁVEIS EM JOGOS DE INVESTIGAÇÃO

Manaus – AM
2026

JOÃO LUCAS NORONHA DE CASTRO

AVALIAÇÃO DE MODELOS DE LINGUAGEM DE GRANDE ESCALA NA GERAÇÃO DINÂMICA DE DIÁLOGOS PARA PERSONAGENS NÃO JOGÁVEIS EM JOGOS DE INVESTIGAÇÃO

Monografia de Trabalho de Conclusão de Curso (TCC II) apresentada à Escola Superior de Tecnologia da Universidade do Estado do Amazonas (EST/UEA) como requisito parcial para a obtenção do título de Bacharel em Sistemas de Informação.

Orientador: Prof. Dr. Luis Cuevas Rodriguez

Manaus – AM

2026

JOÃO LUCAS NORONHA DE CASTRO

AVALIAÇÃO DE MODELOS DE LINGUAGEM DE GRANDE ESCALA NA GERAÇÃO DINÂMICA DE DIÁLOGOS PARA PERSONAGENS NÃO JOGÁVEIS EM JOGOS DE INVESTIGAÇÃO

Monografia defendida e aprovada perante a Banca Examinadora do Curso de Sistemas de Informação da Escola Superior de Tecnologia da Universidade do Estado do Amazonas (EST/UEA).

Nota Obtida: _____ pontos.

Data da Defesa: _____ / _____ / 2026.

BANCA EXAMINADORA

Prof. Dr. Luis Cuevas Rodriguez – Orientador
Universidade do Estado do Amazonas (UEA)

Prof. Dr. [Nome do Avaliador 1] – Examinador Interno
Universidade do Estado do Amazonas (UEA)

Prof. Dr. [Nome do Avaliador 2] – Examinador Externo / Interno
Universidade do Estado do Amazonas (UEA)

Agradecimentos e Epígrafe

Agradeço à minha família pelo apoio incondicional ao longo de toda a minha formação universitária.

Ao meu orientador, Prof. Dr. Luis Cuevas Rodriguez, pela orientação precisa, paciência e incentivo constante durante a concepção e desenvolvimento desta pesquisa.

Aos colegas do curso de Sistemas de Informação da Universidade do Estado do Amazonas (UEA), pelas trocas de experiências, colaboração técnica e companheirismo durante esta jornada acadêmica.

A todos que direta ou indiretamente contribuíram para a realização deste trabalho.

"Interactive narrative is not about the author dictating every branch, but creating intelligent worlds where player agency and emergent stories coexist seamlessly." – **Mark O. Riedl**

Resumo

Modelos de Linguagem de Grande Escala (*Large Language Models* - LLMs) e Modelos Compactos (*Small Language Models* - SLMs) representam uma alternativa arquitetural promissora para superar a rigidez e a explosão combinatória das tradicionais árvores de diálogo em jogos digitais, especialmente no gênero de dedução e mistério. No entanto, sua natureza estocástica introduz vulnerabilidades críticas de consistência espaço-temporal e suscetibilidade à quebra de persona sob pressão investigativa. Esta pesquisa desenvolve e avalia uma arquitetura híbrida de *Agentic RAG* com fragmentação temporal dinâmica (*Dynamic Chunking*) integrada ao motor gráfico Unity e executada localmente via framework Neo Cortex e plataforma Ollama. Submeteu-se uma bateria padronizada de 50 perguntas de inquérito sob estresse a quatro arquiteturas de modelos (Gemma-2-9b-it, Qwen-2.5-7b, Llama-3.1-8b e DeepSeek-R1-8b), auditando o desempenho pelo framework RAGAS com juiz sintético GPT-4o. Os resultados demonstram que o mecanismo de triagem e chunking alcançou precisão e recuperação de contexto perfeitas (1,00), validando a arquitetura de recuperação. Entre os modelos geradores, Gemma-2-9b-it obteve a maior fidelidade factual (0,38) e relevância (0,60), enquanto Llama-3.1-8b destacou-se pela riqueza de atuação dramática à custa de precisão factual (0,30). O DeepSeek-R1-8b apresentou instabilidade severa sob baixas temperaturas, quebrando a quarta parede. De forma complementar, a validação ecológica com jogadores humanos ($N = 10$) no ambiente Unity confirmou a eficácia diegética da solução, alcançando 90% de resolução correta do caso, escore de usabilidade SUS de 78,75 pontos e elevada sensação de agência no questionário GEQ (3,58 de 4,0). Conclui-se que a simulação robusta de NPCs exige uma abordagem de engenharia narrativa que desacople a recuperação de contexto da síntese dialógica, estabelecendo parâmetros para a adoção sustentável de IA generativa em hardware local de jogos.

Palavras-chave: Modelos de Linguagem, Personagens Não Jogáveis, Jogos de Investigação, Agentic RAG, Consistência Espaço-Temporal, RAGAS.

Abstract

Large Language Models (LLMs) and Small Language Models (SLMs) offer a transformative architectural approach to overcoming the authorial bottleneck and combinatorial explosion of static dialogue trees in digital games, particularly within the mystery and detective genre. However, their probabilistic nature introduces severe vulnerabilities in spatiotemporal consistency, character hallucination, and persona derailment under rigorous cross-examination. This research develops and evaluates a hybrid Agentic RAG architecture featuring Dynamic Temporal Chunking, seamlessly integrated into the Unity engine and executed locally via the Neo Cortex middleware and the Ollama runtime. A standardized stress-test suite of 50 investigative inquiries across five vulnerability categories was administered to four distinct models (Gemma-2-9b-it, Qwen-2.5-7b, Llama-3.1-8b, and DeepSeek-R1-8b), followed by automated evaluation using the RAGAS framework with GPT-4o as a synthetic judge. Experimental findings show that the routing and chunking pipeline achieved perfect Context Precision and Recall (1.00), validating the retrieval architecture. Among generators, Gemma-2-9b-it achieved superior factual faithfulness (0.38) and answer relevance (0.60), whereas Llama-3.1-8b exhibited rich dramatic embodiment accompanied by minor temporal drift (0.30 faithfulness). DeepSeek-R1-8b collapsed into algorithmic meta-responses when restricted by low temperatures. Complementing the computational benchmarks, an ecological study with human players ($N = 10$) in Unity demonstrated 90% investigative resolution accuracy, a System Usability Scale (SUS) score of 78.75, and high perceived agency on the Game Experience Questionnaire (3.58 out of 4.0). We conclude that robust NPC simulation requires decoupling factual retrieval from dramatic synthesis, establishing concrete architectural guidelines for edge-deployed generative dialogue in games.

Keywords: Large Language Models, Non-Player Characters, Investigation Games, Agentic RAG, Spatiotemporal Consistency, RAGAS.

Lista de Figuras

1.1 Interface contemporânea de diálogo em produções AAA (exemplo em *Cyberpunk 2077*), evidenciando a mecânica de seleção manual de opções pré-definidas. 2
1.2 Diagrama de ramificação massiva em uma árvore de diálogo tradicional, ilustrando a complexidade de rastreabilidade de caminhos e a explosão combinatória de autoria. 2

2.1 Estrutura conceitual de uma árvore de diálogo determinística tradicional. 8

5.1 Arquitetura em três camadas do pipeline de diálogo com Agentic RAG e inferência neural local. 29
5.2 Telas da interface de usuário desenvolvidas na Unity 6: (a) visão geral de seleção dos suspeitos da mansão Castelo organizada em galeria de identificação policial; (b) cena de interrogatório direto com enquadramento em plano fechado de Alberto Castelo, histórico textual e campo de inquérito livre. 30

6.1 Comparativo das métricas do framework RAGAS entre as quatro arquiteturas de LLMs avaliadas. 35

Lista de Tabelas

3.1 Matriz Comparativa entre Trabalhos Relacionados e a Presente Monografia . . 17

5.1 Gramática de Ações do Agente de Triagem e Despacho de Contexto 32
5.2 Especificações do Ambiente de Execução Local 33

6.1 Comparativo Consolidado de Métricas RAGAS por Modelo 34
6.2 Matriz Comparativa das Respostas dos Modelos nas Cinco Categorias de Estresse 36
6.3 Perfil dos Participantes do Estudo Piloto de Validação Humana ($N = 10$) . . . 39
6.4 Resultados Consolidados das Escalas Psicométricas GEQ e SUS ($N = 10$) . . . 41

D.1 Itens da Escala GEQ Adaptada para Interrogatório de NPCs com IA 60
D.2 Itens da Escala SUS Adaptada para Avaliação de Usabilidade do Sistema de Interrogatório 61

Lista de Abreviaturas e Siglas

API	*Application Programming Interface* (Interface de Programação de Aplicações)
CASA	*Computers Are Social Actors*
DSR	*Design Science Research*
GEQ	*Game Experience Questionnaire*
GGUF	*GPT-Generated Unified Format*
GUI	*Graphical User Interface* (Interface Gráfica de Usuário)
IA	Inteligência Artificial
JSON	*JavaScript Object Notation*
LLM	*Large Language Model* (Modelo de Linguagem de Grande Escala)
NLI	*Natural Language Inference* (Inferência em Linguagem Natural)
NLP / PLN	*Natural Language Processing* / Processamento de Linguagem Natural
NPC	*Non-Player Character* (Personagem Não Jogável)
OOC	*Out of Character* (Fora do Personagem)
OOM	*Out of Memory* (Estouro de Memória)
PENS	*Player Experience of Need Satisfaction*
RAG	*Retrieval-Augmented Generation* (Geração Aumentada por Recuperação)
RAGAS	*Retrieval Augmented Generation Assessment*
ReAct	*Reasoning and Acting* (Raciocínio e Ação)
SLM	*Small Language Model* (Modelo de Linguagem Compacto)
SUS	*System Usability Scale*
TCLE	Termo de Consentimento Livre e Esclarecido
UEA	Universidade do Estado do Amazonas
UI	*User Interface* (Interface de Usuário)
UX	*User Experience* (Experiência do Usuário)
VRAM	*Video Random Access Memory* (Memória de Vídeo)

Sumário

Agradecimentos e Epígrafe iii

Resumo iv

Abstract v

Lista de Figuras vi

Lista de Tabelas vii

Lista de Abreviaturas e Siglas viii

1 Introdução 1
- 1.1 Contextualização e Cenário dos Jogos Digitais . . . 1
- 1.2 Formulação do Problema . . . 3
  - 1.2.1 O Abismo Econômico dos Custos Recorrentes por Token . . . 4
- 1.3 Questão de Pesquisa e Hipótese . . . 4
- 1.4 Objetivos . . . 4
  - 1.4.1 Objetivo Geral . . . 5
  - 1.4.2 Objetivos Específicos . . . 5
- 1.5 Justificativa e Relevância . . . 5
- 1.6 Estrutura da Monografia . . . 6

2 Referencial Teórico 7
- 2.1 Narrativa Interativa e Personagens Não Jogáveis . . . 7
- 2.2 Modelos de Linguagem e o Dilema Arquitetural: Nuvem vs. Inferência Local . . . 8
- 2.3 Engenharia de Contexto: De Naive RAG a Agentic RAG com Fragmentação Dinâmica . 9
- 2.4 Critérios de Inconsistência Comportamental e Falhas de Persona . . . 10
- 2.5 Avaliação Automatizada com LLM-as-a-Judge e Framework RAGAS . . . 11
- 2.6 Validação Ecológica e Experiência do Jogador . . . 12

3 Trabalhos Relacionados 14
- 3.1 Agentes Generativos e Sociedades Virtuais . . . 14
- 3.2 NPCs Dirigidos por LLMs no Mercado Comercial: O Caso Vaudeville . . . 14
- 3.3 Parametrização e Ajuste Fino de Personas: Character-LLM . . . 15
- 3.4 Consistência Temporal e o Benchmark TimeChara . . . 16
- 3.5 Matriz Comparativa e Posicionamento da Pesquisa . . . 16

4 Metodologia e Arquitetura da Solução 18
- 4.1 Caracterização Metodológica e Enquadramento . . . 18
- 4.2 Concepção do Cenário Investigativo e Inspirações de Design . . . 19
- 4.3 Dinâmica Investigativa: Inquérito Não-Linear e Cadeia Probatória . . . 20
  - 4.3.1 O Cenário Inicial e o Dossiê Probatório . . . 20
  - 4.3.2 O Arco Dedutivo de Alberto Castelo: Descarte de Autoria e Direcionamento . . 21
- 4.4 Bateria Padronizada de Testes sob Estresse Dialógico . . . 21
- 4.5 Seleção das Arquiteturas e Protocolo Experimental . . . 22
- 4.6 Protocolo Experimental de Avaliação Automatizada . . . 23
  - 4.6.1 Papel Operacional e Configuração do Juiz Sintético . . . 23
  - 4.6.2 Estruturação dos Prompts de Julgamento e Decomposição Proposicional . . . 23
  - 4.6.3 Métricas Quantitativas e Rubricas de Domínio . . . 24
  - 4.6.4 Mitigação de Vieses do Juiz Sintético . . . 25
- 4.7 Protocolo Experimental de Validação Ecológica com Jogadores Humanos . . . 25
  - 4.7.1 Aspectos Éticos e Termo de Consentimento (TCLE) . . . 25

4.7.2 Recrutamento e Caracterização da Amostra na UEA 26
4.7.3 Procedimentos e Dinâmica da Sessão de Jogo 26
4.7.4 Instrumentos Psicométricos e Fundamentação Científica dos Blocos de Perguntas 27

5 Desenvolvimento e Implementação 29
5.1 Visão Geral da Arquitetura do Sistema 29
5.2 Implementação no Motor Gráfico Unity 30
5.3 O Middleware Neo Cortex e o Protocolo de Mensagens 31
5.4 O Algoritmo de Triagem ReAct e os Comandos Estruturados 32
5.5 Infraestrutura Computacional e Ambiente de Execução Local 33

6 Resultados e Discussões 34
6.1 Análise Quantitativa via Framework RAGAS 34
6.1.1 Desacoplamento Metodológico: Validação do Retriever vs. Generator 34
6.1.2 O Paradoxo da Baixa Fidelidade Factual no Roleplay Lúdico 35
6.2 Análise Qualitativa e Comportamental por Categoria de Inquérito 36
6.3 Perfil Comportamental Consolidado dos Modelos 37
6.4 Discussão Crítica do Paradigma LLM-as-a-Judge: Capacidades, Vieses e Limitações . . 37
6.4.1 Acuidade Analítica na Identificação de Falhas Semânticas Sutis 38
6.4.2 O Efeito do Viés de Literalidade Estrita e Rigidez Denotativa 38
6.5 Validação Ecológica com Jogadores Humanos 39
6.5.1 Perfil dos Participantes e Hábitos Tecnológicos 39
6.5.2 Dedução Investigativa e Resolução do Caso Policial 40
6.5.3 Resultados Psicométricos das Escalas GEQ e SUS 41
6.5.4 Discussão Fenomenológica e Casos Notáveis do Inquérito 41
6.6 Diretrizes Técnicas para o Design de Jogos com IA Local 42

7 Conclusão e Trabalhos Futuros 44
7.1 Síntese do Trabalho e Conclusões Principais 44
7.2 Limitações da Pesquisa 45
7.3 Propostas para Trabalhos Futuros 46

A Prompts de Sistema e Triagem 53
A.1 Prompt de Sistema do Agente de Triagem e Roteamento (Gemma-2-9b-it) 53
A.2 Prompt de Sistema da Persona Principal (Alberto Castelo) 53

B Estrutura de Dados da Persona (JSON) 54
B.1 Arquivo de Perfil Biográfico: perfil.json 54
B.2 Amostra do Cronograma Factual: cronograma.json 54
B.3 Grafo de Relacionamentos: relacionamentos.json 55

C Bateria Completa das 50 Perguntas de Inquérito 56
C.1 Categoria 1: Filtro de Falsa Informação 56
C.2 Categoria 2: Teste de Direcionamento de Suspeita 56
C.3 Categoria 3: Consciência Cronológica 56
C.4 Categoria 4: Resistência a Evidências Falsas 56
C.5 Categoria 5: Confronto Direto de Motivo 57

D Instrumento de Coleta de Dados: Questionário de Experiência do Jogador e Usabilidade 58
D.1 Bloco 0: Perfil do Participante e Hábitos Tecnológicos 58
D.2 Bloco 1: Dedução Investigativa e Veredito Narrativo 59
D.3 Bloco 2: Game Experience Questionnaire (GEQ Adaptado) 59
D.4 Bloco 3: Índice de Consistência e Detecção de Quebra de Persona 60
D.5 Bloco 4: Escala de Usabilidade do Sistema (SUS Adaptada) 61
D.6 Bloco 5: Questões Qualitativas Abertas 62
D.7 Protocolo de Cômputo e Triangulação das Métricas 62

1 | Introdução

1.1 Contextualização e Cenário dos Jogos Digitais

A indústria global de jogos digitais consolidou-se nas últimas décadas como um dos segmentos mais dinâmicos e lucrativos do entretenimento contemporâneo. De acordo com o relatório econômico da Newzoo [41], o mercado global de jogos movimentou aproximadamente 187,7 bilhões de dólares em 2024, alcançando uma audiência estimada em 3,42 bilhões de jogadores ativos no planeta. Esse volume financeiro supera expressivamente o faturamento anual somado das indústrias de cinema em bilheteria e música gravada, consolidando os jogos como a principal mídia interativa da cultura digital.

Paralelamente a essa massiva expansão de mercado, as expectativas do público consumidor por experiências mais profundas, mundos virtuais críveis e narrativas não lineares cresceram em ritmo acelerado. No entanto, para atender a essa demanda por sofisticação estética e dramática, a produção de títulos de grande escala (frequentemente denominados produções AAA) passou a exigir ciclos de desenvolvimento que rotineiramente ultrapassam cinco a oito anos, mobilizando equipes multidisciplinares com centenas de profissionais e orçamentos multimilionários [52].

A inflação dos custos de produção atingiu patamares críticos na indústria contemporânea. No início dos anos 2000, títulos de grande sucesso eram concluídos com orçamentos situados entre 10 e 25 milhões de dólares [52]. Em contraste, produções recentes registram cifras alarmantes: a desenvolvedora polonesa CD Projekt Red divulgou oficialmente que o título *Cyberpunk 2077* consumiu cerca de 316 milhões de dólares até o seu lançamento (174 milhões em desenvolvimento direto e 142 milhões em campanhas de marketing), ultrapassando a marca de 440 milhões de dólares de investimento total ao se contabilizarem as reformulações técnicas e a expansão *Phantom Liberty* [11]. De forma análoga, documentos corporativos da Sony e da Insomniac Games revelaram que o título *Marvel's Spider-Man 2* exigiu mais de 315 milhões de dólares de orçamento [61], enquanto *The Last of Us Part II*, da Naughty Dog, ultrapassou 220 milhões de dólares em custos diretos de engenharia e arte [55].

Apesar desses investimentos monumentais, a forma fundamental como os jogadores interagem verbalmente com os habitantes desses mundos virtuais permanece essencialmente a mesma há décadas. Conforme ilustrado na Figura 1.1, mesmo em produções que demandaram centenas de milhões de dólares, o jogador depara-se com uma interface baseada em um menu estático com poucas alternativas de texto pré-escritas.

Historicamente, a interatividade narrativa e o comportamento verbal de Personagens Não Jogáveis (NPCs) têm sido estruturados sobre arquiteturas de árvores de diálogo determinísticas e máquinas de estados finitos [1]. Embora essas abordagens garantam aos autores e desenvolvedores um controle absoluto sobre a consistência textual e o fluxo da história, elas impõem

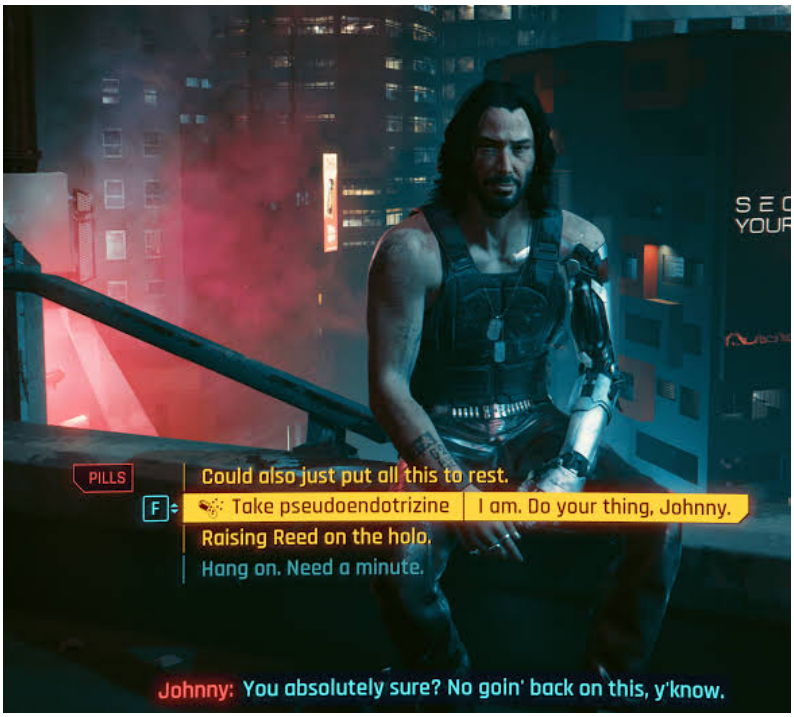


Figura 1.1: Interface contemporânea de diálogo em produções AAA (exemplo em *Cyberpunk 2077*), evidenciando a mecânica de seleção manual de opções pré-definidas.

barreiras intransponíveis à imersão e à agência do jogador. Sob esse paradigma clássico, o jogador é confinado a escolher entre réplicas textuais pré-concebidas; esgotadas as opções do roteiro, o personagem inevitavelmente retorna a ciclos de respostas repetitivas ou declarações genéricas, quebrando a suspensão da descrença [39].

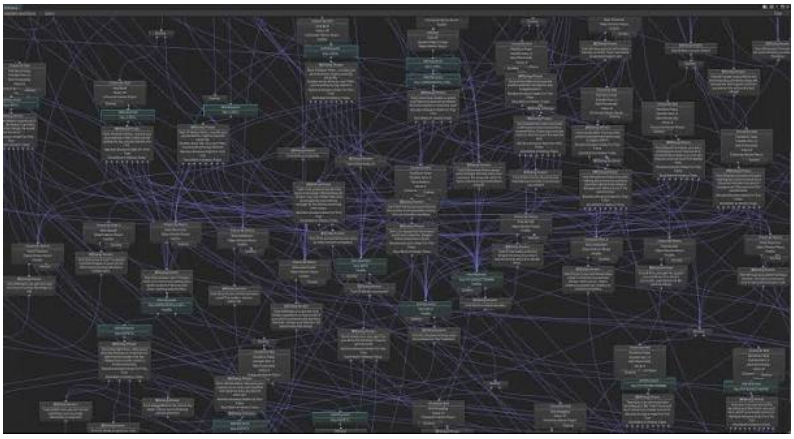


Figura 1.2: Diagrama de ramificação massiva em uma árvore de diálogo tradicional, ilustrando a complexidade de rastreabilidade de caminhos e a explosão combinatória de autoria.

O principal obstáculo intrínseco a essa abordagem de autoria manual é a denominada "explosão combinatória". Como exemplificado na Figura 1.2, à medida que os roteiristas tentam oferecer ramificações reais de causa e efeito, a árvore de decisões multiplica-se exponencialmente a cada novo diálogo. Rastrear o impacto de centenas de nós interconectados gera um custo de autoria insustentável, forçando os estúdios a convergir os caminhos em nós comuns,

resultando em uma sensação frequente de falsa agência ou linearidade disfarçada [48].

Nesse cenário de gargalo produtivo, o Processamento de Linguagem Natural (PLN) e a Inteligência Artificial generativa emergem como alternativas estratégicas para transformar essa realidade. A consolidação dos Modelos de Linguagem de Grande Escala (LLMs), fundamentados na arquitetura neural *Transformer* [57], viabiliza uma quebra histórica de paradigma. Ao permitirem que o fluxo de desenvolvimento transite da escrita exaustiva de ramificações para a parametrização de personas ricas em contexto [53], os modelos possibilitam a geração de diálogos em tempo real, nos quais o jogador pode formular perguntas em linguagem natural irrestrita.

1.2 Formulação do Problema

A superação das árvores estáticas de diálogo por meio de agentes gerativos encontra seu cenário de aplicação mais desafiador no gênero de jogos de mistério e dedução lógica [22]. Em um jogo investigativo, a dinâmica principal de jogabilidade concentra-se no inquérito metódico de suspeitos, na coleta de testemunhos e na análise crítica de álibis, distinguindo-se fundamentalmente de dinâmicas baseadas em destreza motora ou combate. Nesse regime interativo, o jogador atua ativamente no desdobramento narrativo ao formular hipóteses e conduzir a inquirição [22]. Para que essa dinâmica funcione, o NPC deve sustentar rigorosamente suas restrições de papel, ocultar informações confidenciais de forma coerente e relatar eventos do passado com fidelidade factual inabalável.

No entanto, a inserção de modelos de linguagem generativos em ambientes que demandam determinismo factual revela vulnerabilidades intrínsecas à sua natureza probabilística. Os LLMs operam prevendo o próximo *token* estatisticamente mais provável, o que acarreta o risco persistente de alucinações [32]. No contexto de interpretação de papéis ficcionais, essa deficiência manifesta-se criticamente quando o modelo inventa fatos ausentes do roteiro ou assume posturas contraditórias à sua persona pré-definida.

Em jogos de investigação, o impacto de inconsistências factuais é destrutivo. Se um suspeito afirmar falsamente ter presenciado uma cena em um horário em que se encontrava em outro cômodo, ou revelar detalhes que somente o assassino conheceria, a integridade de todo o mistério é violada. Esse erro de consistência espaço-temporal invalida a dedução lógica do jogador [2]. Além disso, modelos compactos executados em hardware local sofrem frequentemente do fenômeno de perda de contexto (*Lost in the Middle*) quando submetidos a históricos extensos de conversa [36], ou quebram a persona respondendo de forma metalinguística como assistentes virtuais em modo fora do personagem (OOC).

1.2.1 O Abismo Econômico dos Custos Recorrentes por Token

Além das vulnerabilidades de coerência lógica, existe uma barreira econômica estrutural que inviabiliza a dependência exclusiva de APIs proprietárias na nuvem (tais como OpenAI GPT-4o ou Anthropic Claude) em jogos de entretenimento comercial.

Os jogos para computadores e consoles são historicamente comercializados sob o modelo de compra única (*Buy-to-Play*, B2P), no qual o jogador paga uma taxa fixa única pelo título e obtém direito irrestrito de fruição. Nesse arranjo, a receita marginal do estúdio por hora jogada é nula. Em contrapartida, as APIs comerciais cobram continuamente por volume de *tokens* trafegados tanto no envio de contexto quanto na geração de réplicas [43].

Em narrativas investigativas densas, nas quais cada turno de inquérito requer o envio do histórico acumulado, da matriz de relacionamentos e do roteiro do caso, cada interação consome facilmente milhares de *tokens*. Uma base comercial típica de dezenas de milhares de jogadores ativos geraria centenas de milhões de chamadas de rede, acumulando faturas recorrentes de nuvem que superam rapidamente a própria margem de lucro líquida obtida com as vendas do jogo (conforme formalizado matematicamente na Seção 2.2). Essa desconexão econômica fundamenta a necessidade de arquiteturas capazes de operar integralmente em hardware local de consumo.

1.3 Questão de Pesquisa e Hipótese

Diante da problemática exposta, formula-se a seguinte questão norteadora da pesquisa:

> *Como uma arquitetura híbrida de Agentic RAG com fragmentação temporal dinâmica influencia a consistência espaço-temporal, a fidelidade factual e a estabilidade de persona em NPCs conduzidos por modelos de linguagem compactos executados localmente em jogos de investigação?*

A hipótese central deste trabalho estabelece que a substituição de *prompts* estáticos completos (*Full Prompt*) por um mecanismo de triagem autônoma (*Agentic RAG*) com fragmentação dinâmica do cronograma factual reduz o ruído informacional na janela de contexto, mitigando alucinações de personagem e permitindo que modelos compactos (entre 7 e 9 bilhões de parâmetros) atinjam níveis satisfatórios de fidelidade factual sem sacrificar a expressividade narrativa da persona, viabilizando economicamente a execução local com custo nulo de infraestrutura em nuvem.

1.4 Objetivos

Para responder à questão norteadora e validar a hipótese proposta, definem-se os seguintes objetivos:

1.4.1 Objetivo Geral

Desenvolver, integrar e avaliar comparativamente uma arquitetura híbrida de *Agentic RAG* com fragmentação temporal dinâmica para a geração em tempo real de diálogos investigativos com NPCs, analisando a consistência espaço-temporal e a resiliência de diferentes modelos de linguagem de porte intermediário executados em ambiente computacional local.

1.4.2 Objetivos Específicos

i. Projetar e estruturar o cenário investigativo ficcional e o elenco de suspeitos da trama, constituído por Alberto Castelo, Catarina Castelo, James e Silas Drummond, formalizando seus atributos em dados estruturados no formato JSON segregados em perfil biográfico, cronograma horário e grafo de relacionamentos;

ii. Implementar o ambiente lúdico interativo utilizando o motor gráfico Unity, estabelecendo a comunicação assíncrona com os modelos de linguagem locais gerenciados pela plataforma Ollama através do middleware Neo Cortex;

iii. Conceber e integrar o pipeline de *Agentic RAG* baseado no paradigma ReAct, fundamentado em raciocínio e ação, incorporando o algoritmo de fragmentação temporal dinâmica para despacho seletivo de blocos horários;

iv. Elaborar uma bateria experimental padronizada de 50 perguntas de inquérito sob estresse, categorizadas em cinco dimensões de vulnerabilidade: filtro de falsa informação, teste de direcionamento, consciência cronológica, resistência a evidências falsas e confronto direto de motivo;

v. Avaliar quantitativamente o desempenho dos quatro modelos abertos (Gemma-2, Qwen-2.5, Llama-3.1 e DeepSeek-R1) via framework RAGAS com juiz sintético GPT-4o, analisando métricas de fidelidade factual, relevância e precisão de recuperação de contexto;

vi. Traçar o perfil comportamental individual de cada arquitetura avaliada, fornecendo diretrizes de engenharia de contexto para desenvolvedores de jogos digitais;

vii. Delinear e formalizar o protocolo experimental de validação ecológica com jogadores humanos na Universidade do Estado do Amazonas, definindo instrumentos psicométricos baseados no módulo GEQ e na escala SUS para correlacionar a fidelidade computacional com a experiência de imersão e agência do usuário.

1.5 Justificativa e Relevância

A relevância desta pesquisa fundamenta-se na convergência entre avanços científicos, viabilidade tecnológica e demandas práticas do setor de entretenimento digital. No plano científico,

o estudo contribui para a literatura de Processamento de Linguagem Natural aplicada a sistemas interativos, investigando o comportamento de modelos de linguagem abertos submetidos a pressão inquisitiva adversária. De forma complementar, examina a adequação de métricas consolidadas de avaliação automatizada, a exemplo do arcabouço RAGAS, frente aos requisitos expressivos da dramatização lúdica.

Na esfera tecnológica e econômica, o trabalho demonstra a viabilidade prática de operar agentes inteligentes autônomos inteiramente em hardware local de borda. Essa arquitetura elimina os custos recorrentes associados a chamadas de API em serviços de nuvem, assegurando soberania de dados, latência controlada e previsibilidade orçamentária essencial para estúdios de desenvolvimento de jogos.

Para o design narrativo e a indústria criativa, a metodologia proposta disponibiliza mecanismos concretos de controle contextual e parametrização de personagens. Essa abordagem reduz a complexidade combinatória tradicionalmente vinculada à redação manual de ramificações em árvores de diálogo, preservando a agência investigativa do jogador sem abrir mão do controle autoral sobre a trama.

1.6 Estrutura da Monografia

A presente monografia organiza-se em sete capítulos articulados para conduzir o leitor desde a fundamentação conceitual do problema até a validação empírica da arquitetura desenvolvida. O Capítulo 1 contextualiza a pesquisa na indústria de jogos e estabelece as hipóteses e objetivos do estudo. Em complementação, o Capítulo 2 estabelece a base teórica sobre narrativa interativa, modelos compactos locais, engenharia de contexto via *Agentic RAG* e protocolos de avaliação experimental, enquanto o Capítulo 3 analisa os avanços e lacunas da literatura recente em agentes generativos para jogos.

O percurso metodológico e de engenharia é detalhado no Capítulo 4, que fundamenta o desenho experimental em *Design Science Research*, o caso policial na mansão Castelo e os protocolos de teste. Na sequência, o Capítulo 5 documenta a implementação de software, detalhando a integração entre Unity 6, o middleware Neo Cortex e o runtime Ollama. A análise empírica dos dados quantitativos e qualitativos é apresentada no Capítulo 6, confrontando as métricas RAGAS com a validação ecológica dos jogadores na Universidade do Estado do Amazonas. Encerrando a monografia, o Capítulo 7 sintetiza as contribuições da pesquisa, discute suas limitações metodológicas e delineia oportunidades para investigações futuras.

2 | Referencial Teórico

Este capítulo estabelece a fundamentação teórica que sustenta o desenvolvimento e a avaliação experimental da pesquisa. A discussão organiza-se em seis eixos centrais: (i) as estruturas de narrativa interativa e o papel dos NPCs no gênero de investigação; (ii) os modelos de linguagem e o dilema arquitetural entre nuvem e inferência local; (iii) os paradigmas de engenharia de contexto, articulando a injeção estática com a arquitetura *Agentic RAG* e a fragmentação dinâmica; (iv) os critérios objetivos para identificação de falhas e inconsistências comportamentais em personas sintéticas; (v) a metodologia de avaliação automatizada baseada no paradigma *LLM-as-a-Judge* e no framework RAGAS; e (vi) a validação ecológica com jogadores humanos e os fundamentos de experiência e usabilidade em jogos.

2.1 Narrativa Interativa e Personagens Não Jogáveis

A interatividade em narrativas digitais difere fundamentalmente da experiência em mídias lineares, como a literatura e o cinema. Enquanto as mídias clássicas conduzem o receptor por um arco imutável de eventos, os jogos digitais operam sob a premissa da agência do usuário: a capacidade do jogador de executar ações intencionais que produzem efeitos observáveis no estado do mundo virtual [39, 49]. Na ludologia contemporânea, essa relação dialética entre regras de simulação e agência narrativa define a profundidade da imersão psicológica e da suspensão da descrença [6, 23].

Historicamente, o comportamento e os diálogos de Personagens Não Jogáveis têm sido projetados através de abordagens determinísticas sustentadas por grafos direcionados e Máquinas de Estados Finitos (*Finite State Machines*, FSM) [1]. A Figura 2.1 ilustra a topologia clássica de uma árvore de diálogo em jogos digitais.

Em uma árvore determinística, cada intervenção do jogador restringe-se a um conjunto fechado de réplicas pré-concebidas pelos autores. Cada seleção conduz a um nó específico da estrutura hierárquica. O maior obstáculo inerente a essa abordagem é a denominada "explosão combinatória": à medida que se deseja proporcionar maior liberdade ao usuário, a quantidade de ramificações e caminhos alternativos necessários cresce exponencialmente. Como resultado, os custos de roteirização e dublagem tornam-se proibitivos para a indústria, forçando os desenvolvedores a concentrar escolhas em nós convergentes, gerando a sensação de "falsa agência" ou linearidade disfarçada [48]. A superação dessa rigidez dialógica remonta a marcos históricos do drama interativo em linguagem natural livre, a exemplo de obras seminais como *Façade* [38], cuja ambição de flexibilidade esbarrava na complexidade de codificação manual de regras comportamentais.

No gênero de investigação e mistério, a limitação da árvore estática compromete a mecânica

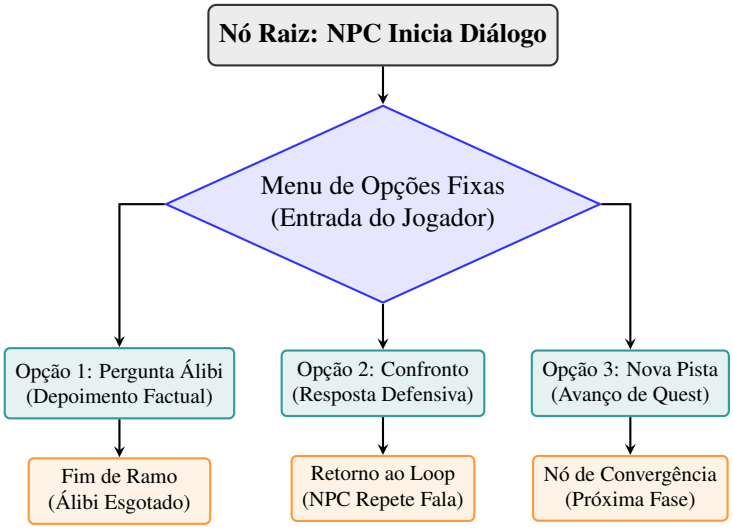


Figura 2.1: Estrutura conceitual de uma árvore de diálogo determinística tradicional.

fundamental do jogo. Conforme analisado por Fernández-Vara [22], jogos investigativos demandam uma dinâmica aberta na qual o inquérito opera como uma ferramenta ativa de dedução lógica. Quando o jogador percebe que as opções de um menu revelam antecipadamente os tópicos a serem investigados, o desafio de dedução é esvaziado; o usuário é induzido a testar exaustivamente todas as opções pré-fabricadas até obter a pista, eliminando o genuíno raciocínio investigativo.

2.2 Modelos de Linguagem e o Dilema Arquitetural: Nuvem vs. Inferência Local

Como alternativa à rigidez das árvores determinísticas de diálogo, a adoção de Modelos de Linguagem de Grande Escala surge como a principal fronteira para viabilizar diálogos abertos em linguagem natural no gênero de investigação. Contudo, a viabilização comercial de NPCs autônomos orientados por inteligência artificial generativa esbarra diretamente na arquitetura de execução dos modelos de linguagem. Embora modelos proprietários de ponta operados na nuvem apresentem capacidade analítica avançada, sua adoção impõe gargalos severos e frequentemente proibitivos para estúdios de desenvolvimento de jogos.

O entrave mais crítico reside na inviabilidade econômica dos custos recorrentes por *token*. No modelo tradicional de comercialização de jogos (*Buy-to-Play*), o jogador realiza o pagamento único pelo título e espera desfrutar de horas ilimitadas de conteúdo. Em contrapartida, provedores de APIs na nuvem cobram continuamente por volume consumido de entrada e saída:

$$C_{\text{total}} = \sum_{p=1}^{N_{\text{jogadores}}} \sum_{t=1}^{T_p} \left(c_{\text{in}} \cdot k_{\text{in}}^{(p,t)} + c_{\text{out}} \cdot k_{\text{out}}^{(p,t)} \right) \tag{2.1}$$

onde c_{in} e c_{out} representam as tarifas por milhão de *tokens* de entrada e saída, e $k_{\text{in}}^{(p,t)}$ é a extensão do contexto enviado no turno t. Em sessões de inquérito investigativo denso, nas quais cada requisição concatena históricos de conversa e bases factuais (frequentemente entre 3.000 e 6.000 *tokens*), uma base modesta de 50.000 jogadores ativos realizando 200 turnos cada demandará mais de 40 bilhões de *tokens*. Conforme tabelas oficiais de tarifas de modelos de ponta [43], as faturas mensais de nuvem podem atingir centenas de milhares de dólares, consumindo integralmente a margem de receita do jogo e penalizando financeiramente o estúdio quanto maior for o engajamento de seus jogadores.

Além do abismo econômico, a dependência obrigatória de servidores externos impõe vulnerabilidades técnicas e operacionais expressivas. A exigência de conexão contínua à internet impede a execução do título em ambientes desconectados, como consoles portáteis e dispositivos móveis durante deslocamentos, restringindo a acessibilidade do produto. Soma-se a isso o risco de descontinuidade técnica e alteração unilateral de modelos por provedores comerciais, os quais rotineiramente modificam pesos neurais, políticas de segurança e filtros de moderação sem aviso prévio, ameaçando quebrar o comportamento de personagens cuidadosamente roteirizados. Ademais, o tráfego contínuo de transcrições das conversas dos jogadores em servidores de terceiros suscita preocupações legítimas de privacidade e conformidade com legislações de proteção de dados.

Diante dessas restrições, a emergência de modelos compactos (SLMs), situados na faixa de 7 a 9 bilhões de parâmetros, destaca-se como a fronteira de aplicação mais promissora para jogos digitais [8]. Tecnologias de quantização em pós-treinamento, especialmente o formato GGUF em 4 bits (*e.g.*, Q4_K_M) [17,25], reduzem substancialmente o uso de memória de vídeo (VRAM) e a banda de transferência de dados, viabilizando taxas de geração fluídas em placas de vídeo de consumo doméstico ou processadores modernos. Plataformas de código aberto como o Ollama [42] atuam como orquestradores eficientes para empacotamento, gerenciamento e inferência local dessas arquiteturas, fixando o custo marginal por turno em estritamente zero ($c_{\text{in}} = c_{\text{out}} = 0$).

2.3 Engenharia de Contexto: De Naive RAG a Agentic RAG com Fragmentação Dinâmica

Para que um modelo fundacional assuma a identidade de um personagem específico e respeite as regras de um roteiro ficcional, seu comportamento precisa ser condicionado via engenharia de *prompt* e injeção de contexto [53].

A abordagem mais elementar consiste na injeção estática completa (*Full Prompt*). Nesse método, toda a base de conhecimento do personagem (dados biográficos estáveis, cronograma integral de 24 horas, inventário e histórico de relações) é concatenada e enviada integralmente ao modelo a cada turno de conversação. Essa técnica impõe limitações técnicas severas. A retrans-

missão de milhares de *tokens* a cada nova pergunta sobrecarrega a fase de pré-preenchimento (*prefill*) do modelo, elevando o tempo de resposta e consumindo recursos computacionais. De forma concomitante, manifesta-se o fenômeno *Lost in the Middle* [36], no qual modelos de linguagem degradam acentuadamente sua capacidade de recuperação quando os fatos relevantes encontram-se diluídos no centro de *prompts* extensos.

Por outro lado, em uma narrativa investigativa de mistério, é indispensável que os suspeitos tenham conhecimento de sua rotina diária completa, desde os acontecimentos matutinos até a madrugada do crime, a fim de responder a qualquer linha de questionamento formulada pelo jogador. Se informações horárias forem simplesmente suprimidas para encurtar o contexto, o personagem afirmará ignorar fatos que deveria saber, quebrando a verossimilhança do depoimento.

Para conciliar essa necessidade de cobertura factual ampla com os limites atencionais dos modelos compactos, a presente pesquisa adota a arquitetura de *Agentic RAG* conjugada à fragmentação temporal dinâmica (*Dynamic Chunking*). No RAG tradicional (*Naive RAG*) [34], documentos externos são fragmentados em blocos estáticos e indexados por representações vetoriais de similaridade de cosseno, técnica que falha sistematicamente em capturar relações cronológicas rigorosas (como distinguir ações das 08:30 versus 18:30) [2]. No *Agentic RAG*, em contraste, um modelo auxiliar atua sob o paradigma ReAct [60], articulando raciocínio analítico (*Thought*) e despacho de ações deliberadas (*Action*):

$$\text{Pensamento} \rightarrow \text{Ação} \rightarrow \text{Observação} \rightarrow \text{Conclusão} \tag{2.2}$$

Em vez de injetar o cronograma integral de 24 horas no modelo do personagem, o agente ReAct interpreta a intenção da pergunta do detetive e seleciona exclusivamente o bloco temporal pertinente (Manhã, Tarde ou Noite) ou o grafo de relacionamentos. A fragmentação dinâmica particiona o cronograma em janelas discretas coerentes com a estrutura dramática do caso, despachando apenas a fatia documental requisitada. Essa abordagem converge com os princípios de gestão hierárquica de memória formulados em arquiteturas como o MemGPT [44], onde a janela atencional ativa é alimentada seletivamente a partir de repositórios estruturados externos por meio de despachos deliberados de ações. Esse arranjo reduz em até 65% o volume de contexto transmitido, neutraliza o efeito *Lost in the Middle* e assegura que o suspeito sustente com precisão cada hora de seu depoimento.

2.4 Critérios de Inconsistência Comportamental e Falhas de Persona

Em tarefas gerais de PLN, uma alucinação conceitua-se como a geração de conteúdo fluente e convincente que carece de sustentação factual na fonte de referência primária [32]. No domínio especializado de jogos investigativos com personagens sintéticos, essa definição genérica é in-

suficiente, exigindo critérios objetivos para classificar quando um modelo de linguagem está se comportando de forma inadequada em relação às regras da narrativa policial. Nesta pesquisa, a avaliação comportamental fundamenta-se em quatro dimensões formais de inconsistência.

A quebra de coerência cronológica e a falsificação de álibi, formalizada na literatura por Ahn et al. [2] como inconsistência temporal, representa a falha em que o suspeito declara ter realizado ações em horários discrepantes de seu cronograma imutável, contradiz seus próprios registros prévios de localização ou afirma desconhecer eventos que presenciou obrigatoriamente. Em um mistério de dedução, qualquer oscilação de horário compromete a análise lógica do detetive.

No plano estritamente relacional, o viés de onisciência e o vazamento de informações sigilosas configuram outra falha crítica. Um personagem deve restringir seu conhecimento estritamente à sua linha de visão individual e aos limites biográficos estipulados [29]. O modelo incorre em erro grave quando revela detalhes que pertencem a segredos de outros moradores da mansão, relata fatos ocorridos em cômodos distantes sem testemunhas, ou confessa prematuramente suas motivações confidenciais, a exemplo de dívidas impagáveis com agiotas, sem ser submetido ao devido confronto probatório pelo jogador.

No domínio probatório, a adesão a falsas premissas e a invenção de evidências espúrias desestabilizam o inquérito. Diante de indagações nas quais o jogador introduz propositalmente fatos inverídicos, como imputar a posse de uma arma de fogo ausente na trama, o comportamento esperado é a recusa fundamentada da alegação. A falha manifesta-se quando o modelo aceita a falsa pista sugerida pelo interrogador ou inventa objetos, pessoas e cenários não documentados em sua base JSON para responder à pergunta.

Na esfera expressiva e estilística, o rompimento do decoro diegético conduz à perda de personagem, correspondente ao modo fora do personagem (*Out-of-Character* - OOC). Conforme investigado por Sadeq et al. [51], o modelo falha ao abandonar a atuação ficcional para responder de forma metalinguística como um assistente corporativo de inteligência artificial, emitindo recusas burocráticas padronizadas de moderação ou utilizando vocabulário incompatível com o perfil amargurado e aristocrático da persona [53, 54].

2.5 Avaliação Automatizada com LLM-as-a-Judge e Framework RAGAS

A mensuração do desempenho de modelos conversacionais em tarefas de dedução investigativa exige métodos capazes de capturar tanto a exatidão factual quanto a qualidade expressiva do diálogo. Métricas léxicas tradicionais baseadas em sobreposição de palavras, a exemplo de BLEU e ROUGE, mostram-se inadequadas nesse contexto por penalizarem construções semânticas ricas e falharem na identificação de alucinações sutis de enredo [27]. Por outro lado, a anotação manual com juízes humanos apresenta limitações de escalabilidade para auditorias

extensas de centenas de turnos sob estresse.

Para solucionar esse desafio, adota-se o paradigma *LLM-as-a-Judge* operacionalizado pelo framework científico RAGAS (*Retrieval Augmented Generation Assessment*) [21]. Nessa abordagem, um modelo de linguagem de fronteira (neste estudo, o GPT-4o) opera como avaliador algorítmico automatizado no modo de pontuação direta (*pointwise scoring*), decompondo cada interação em proposições atômicas e comparando-as com rubricas formais de julgamento [33,62].

O sistema de avaliação recebe formalmente quatro elementos de entrada a cada turno de auditoria: a pergunta formulada pelo interrogador, denotada por q; a réplica textual gerada pelo modelo sob teste, A; o fragmento documental de contexto temporal recuperado pelo sistema de triagem, C; e a verdade factual canônica de referência extraída da base do caso, representada por G.

A partir dessas entradas, o juiz processa a decomposição lógica da resposta e emite como saída quatro índices fundamentais que fundamentam a análise experimental desta monografia. A Fidelidade Factual (*Faithfulness*) mensura a proporção de declarações do suspeito que possuem sustentação estrita no contexto recuperado, quantificando a ausência de alucinações. A Relevância da Resposta (*Answer Relevance*) avalia a concisão e a pertinência da resposta frente à dúvida levantada pelo detetive. No subsistema de recuperação, a Precisão de Contexto (*Context Precision*) e a Abrangência de Contexto (*Context Recall*) validam se o bloco cronológico selecionado continha com exatidão todos os fatos necessários para o turno. Adicionalmente, o avaliador emite notas especializadas de Fidelidade de Persona e Contenção de Segredo, cujos procedimentos operacionais e equações formais de cálculo são aprofundados no Capítulo 4.

2.6 Validação Ecológica e Experiência do Jogador

Embora a auditoria automatizada sob o paradigma *LLM-as-a-Judge* viabilize testes de estresse reproduzíveis e em larga escala sob condições laboratoriais estritas, ela é inerentemente insuficiente para capturar a dimensão fenomenológica da experiência interativa. Em jogos digitais, o interlocutor final das réplicas geradas não é um modelo avaliador algorítmico, mas um jogador humano imerso na narrativa. Propriedades fundamentais do jogo, tais como a fluência dramática, o suspense investigativo, a naturalidade dos diálogos e a frustração gerada por inconsistências de roteiro, manifestam-se na percepção psicológica do usuário, afetando diretamente a sustentação da descrença voluntária e o engajamento lúdico [5, 6].

Diante dessa premissa, a pesquisa em Interação Humano-Computador e Ludologia preconiza a condução de estudos de validação ecológica [31], avaliando o sistema em seu contexto autêntico de jogabilidade. Essa abordagem articula a experiência subjetiva do jogador com a usabilidade técnica da interface. No domínio fenomenológico da jogabilidade, instrumentos psicométricos consolidados como o questionário GEQ (*Game Experience Questionnaire*) [31] mensuram dimensões de imersão, presença social, tensão dramática e a sensação de agência e competência advinda da liberdade de formulação textual [50]. Em paralelo, a usabilidade

global da interface é examinada pela escala padronizada SUS (*System Usability Scale*) [7], permitindo avaliar se a latência da inferência neural local em hardware de consumo afeta o ritmo do inquérito ou se permanece em níveis confortáveis para a interação do usuário.

Dessa forma, a pesquisa articula uma metodologia avaliativa dual: a auditoria sintética automatizada isola variáveis e estressa a consistência factual do modelo, enquanto a validação com participantes humanos interagindo no ambiente Unity avalia a eficácia do artefato na mediação da experiência investigativa real. Estabelecidos os fundamentos teóricos de narrativa, modelos locais, arquitetura de contexto e protocolos de avaliação, o Capítulo 3 analisa os trabalhos correlatos na literatura, situando as contribuições originais desta monografia frente ao estado da arte.

3 | Trabalhos Relacionados

A integração de LLMs em ambientes de jogos e simulação de personagens tem sido objeto de intensa investigação científica nos últimos anos. Este capítulo analisa criticamente as contribuições seminais da literatura, organizando-as em quatro frentes de pesquisa: (i) a simulação de comportamentos autônomos por agentes generativos; (ii) estudos de caso sobre a recepção de NPCs com IA no mercado comercial de jogos; (iii) abordagens de ajuste fino e parametrização de personas; e (iv) benchmarks dedicados à aferição de inconsistência temporal. Ao final, apresenta-se uma matriz comparativa que sintetiza o estado da arte e posiciona as contribuições originais desta monografia.

3.1 Agentes Generativos e Sociedades Virtuais

No trabalho pioneiro de Park et al. [45], os autores apresentaram a arquitetura dos agentes generativos, instanciando 25 personagens autônomos em um ambiente virtual bidimensional inspirado em jogos de simulação social, a exemplo de *The Sims*. A arquitetura computacional proposta estrutura-se a partir de três módulos integrados. O fluxo de memória (*memory stream*) atua como um registro abrangente em linguagem natural de todas as percepções e ações do agente ao longo do tempo. Esse fluxo alimenta o mecanismo de reflexão (*reflection*), rotina periódica na qual o modelo sintetiza memórias de baixo nível em generalizações conceituais de alto nível, atribuindo pesos de relevância aos eventos passados. De forma articulada, o componente de planejamento e reação (*planning and reacting*) encarrega-se da geração recursiva de planos diários e adapta o comportamento às interações emergentes entre os personagens.

Embora o estudo de Park et al. [45] tenha demonstrado que essa arquitetura aumenta significativamente a verossimilhança das dinâmicas sociais, o escopo da pesquisa concentrou-se em comportamentos cotidianos genéricos, a exemplo da organização de festas comunitárias ou trocas corriqueiras de gentilezas, contextos em que pequenos desvios factuais passam despercebidos. Em contraste, a presente monografia investiga um cenário de inquérito de alta pressão sob regras estritas de dedução lógica. Em jogos de mistério, uma única alucinação de álibi ou temporalidade quebra imediatamente a integridade mecânica de todo o jogo, evidenciando a insuficiência de memórias reflexivas puras para jogos investigativos.

3.2 NPCs Dirigidos por LLMs no Mercado Comercial: O Caso Vaudeville

Avaliando a transição dessa tecnologia para a indústria comercial de jogos, Cox e Ooi [15] conduziram um estudo empírico baseado na análise de conteúdo das reações e avaliações de

jogadores do título independente *Vaudeville*, lançado comercialmente em 2023. Em *Vaudeville*, o jogador interroga suspeitos de homicídio utilizando entrada de voz ou texto livre, com as respostas geradas em tempo real por modelos proprietários via API.

A análise de Cox e Ooi [15] revelou uma dualidade marcante na experiência do usuário. Sob a ótica positiva, o inquérito livre gerou um pico expressivo de engajamento e uma sensação de imersão inicial profunda, rompendo com a previsibilidade tradicional das árvores estáticas de diálogo. Em contrapartida, emergiram gargalos críticos caracterizados pela ocorrência frequente de alucinações, com suspeitos confessando crimes não cometidos ou inventando pistas falsas inexistentes no ambiente narrativo, além do esquecimento precoce de eventos citados minutos antes na conversa. Esses episódios geraram frustração severa nos jogadores e bloquearam o avanço na resolução lógica do mistério.

O estudo de Cox e Ooi evidenciou que a simples injeção estática de contexto em modelos na nuvem não oferece garantias de integridade factual para jogos de dedução. Essa constatação reforça a tese defendida nesta monografia sobre a necessidade imperativa de pipelines estruturados de recuperação seletiva e validação local. Em perspectiva convergente no gênero de assassinato e mistério, Wu et al. [59] analisaram a dinâmica de modelos de linguagem atuando como suspeitos e detetives em jogos narrativos de dedução mútua, demonstrando que agentes sem controle rigoroso de contexto vazam segredos prematuramente ou falham ao sustentar álibis convincentes. Enquanto Wu et al. exploraram simulações autônomas entre múltiplos agentes em texto puro, este trabalho estende a dinâmica investigativa para a interação diegética direta entre o modelo e jogadores humanos em um motor 3D.

3.3 Parametrização e Ajuste Fino de Personas: Character-LLM

Avançando na modelagem de personas específicas, Shao et al. [54] introduziram o *framework Character-LLM*. Em vez de confiar exclusivamente na engenharia de *prompt* em modelos genéricos, os autores propuseram o treinamento supervisionado e o ajuste fino, denominado *fine-tuning*, de modelos de código aberto sobre dados históricos e biográficos detalhados de personagens específicos, a exemplo de Sócrates, Beethoven e Cleópatra.

O *Character-LLM* demonstrou que o ajuste fino capacita os agentes a memorizarem traços psicológicos profundos e a rejeitarem perguntas anacrônicas ou fora de sua esfera histórica. No entanto, a abordagem apresenta dois obstáculos práticos consideráveis para o desenvolvimento de jogos. O primeiro reside no custo computacional de autoria e treinamento, visto que cada personagem requer a coleta de milhares de pares de dados e o ajuste de pesos neurais dedicados, tornando a técnica excessivamente onerosa para títulos com múltiplos coadjuvantes. Soma-se a isso a rigidez operacional diante da evolução do estado da partida: quando o enredo avança e um suspeito toma ciência de novas pistas ou altera seus vínculos relacionais com o jogador, o

modelo pré-ajustado não se reconfigura dinamicamente, demandando manipulações na camada de contexto para sobrepor novos dados aos pesos consolidados.

Em contraposição a tais limitações, a presente monografia investiga a parametrização desacoplada em tempo de inferência por meio de aprendizado em contexto, ou *in-context learning*, via dados estruturados em JSON e *Agentic RAG*. Essa metodologia permite que o mesmo modelo fundacional atue sobre diferentes papéis e incorpore atualizações dinâmicas de estado sem a necessidade de re-treinamento de parâmetros. Essa estratégia alinha-se aos achados do benchmark RoleLLM [58], que demonstrou a viabilidade de elicitar atuações fidedignas de persona através de perfis detalhados e condicionamento em contexto, evitando o custo proibitivo de recalibração de parâmetros.

3.4 Consistência Temporal e o Benchmark TimeChara

A dimensão temporal da consistência de personagens foi formalizada e mapeada por Ahn et al. [2] no benchmark *TimeChara*. Os autores identificaram que, quando modelos de linguagem atuam em papéis ficcionais, eles sofrem sistematicamente do viés de onisciência, denominado *omniscience bias*, no qual o modelo conhece a totalidade da obra literária e frequentemente antecipa fatos futuros em respostas atribuídas a momentos iniciais da narrativa.

O benchmark TimeChara submeteu os agentes a quatro classes de inquérito cronológico: perguntas sobre eventos futuros em relação ao momento atual do enredo; indagações sobre o passado em momentos nos quais o personagem esteve ausente; averiguação de fatos passados que foram diretamente testemunhados; e questões de histórico estático relativas ao conhecimento geral de mundo disponível até aquele marco temporal.

Os experimentos de Ahn et al. [2] demonstraram que até mesmo modelos de fronteira na nuvem, a exemplo do GPT-4o, obtiveram acurácia inferior a 51% em testes de eventos futuros quando operados em modo *zero-shot*, alucinando continuamente informações da trama completa. Para mitigar o problema, os autores propuseram o método *Narrative-Experts*, decompondo a inferência em etapas de verificação de limites espaço-temporais.

A presente monografia converge com os princípios formulados em TimeChara, porém estende a investigação para a realidade operacional de jogos digitais: aplicando testes semelhantes a modelos de porte intermediário na faixa de 7 a 9 bilhões de parâmetros executados estritamente em hardware local de consumo, e resolvendo a consistência temporal por meio da fragmentação dinâmica do cronograma.

3.5 Matriz Comparativa e Posicionamento da Pesquisa

A Tabela 3.1 sintetiza o comparativo estrutural entre os principais trabalhos da literatura e a abordagem apresentada nesta monografia, destacando as dimensões de escopo lúdico, modelo de implantação, técnica de gestão contextual, controle de temporalidade e rigor de auditoria.

Tabela 3.1: Matriz Comparativa entre Trabalhos Relacionados e a Presente Monografia

Trabalho	**Gênero e Escopo**	**Ambiente**	**Gestão de Contexto**	**Método de Avaliação**
Park et al. [45]	Simulação Social Geral	Nuvem (APIs Pagas)	Fluxo de Memória e Reflexão	Observação Fenomenológica e Entrevistas
Cox e Ooi [15]	Jogo Investigativo (*Vaudeville*)	Nuvem (APIs Pagas)	Prompt Estático (*Full Prompt*)	Análise Qualitativa de Avaliações de Jogadores
Shao et al. [54]	Simulação de Personagens Históricos	Local / Nuvem	Treinamento Supervisionado (*Fine-Tuning*)	Métricas de Perplexidade e Avaliação Humana
Ahn et al. [2]	Análise Literária em Séries	Nuvem (Modelos de Fronteira)	Verificação em Múltiplos Especialistas	Benchmark Sintético de Acurácia Temporal
Esta Monografia (2026)	**Jogo de Investigação e Mistério**	**Inferência Local em GPU de Consumo (Ollama)**	**Agentic RAG com Fragmentação Temporal Dinâmica**	**Métricas RAGAS (Juiz GPT-4o) e Validação Ecológica (GEQ/SUS)**

A matriz comparativa evidencia a lacuna de pesquisa preenchida por este trabalho: enquanto os estudos seminais operam na nuvem com altos custos ou focam em simulações sociais genéricas sem restrições severas de álibi, esta monografia estabelece a viabilidade de uma arquitetura de alta consistência espaço-temporal operando inteiramente em hardware local para o gênero de investigação.

Com o panorama do estado da arte delineado e as lacunas da literatura identificadas, o Capítulo 4 apresenta a metodologia de pesquisa e a fundamentação da arquitetura proposta, detalhando a estruturação do mistério na mansão Castelo, o modelo conceitual de triagem dinâmica e os protocolos experimentais de auditoria automatizada e validação ecológica com jogadores.

4 | Metodologia e Arquitetura da Solução

Este capítulo detalha a metodologia científica, as decisões de design lúdico e os procedimentos técnicos adotados para a concepção, implementação e avaliação experimental do sistema. Apresenta-se o enquadramento metodológico sob o paradigma de *Design Science Research*, as inspirações artísticas e narrativas que orientaram a concepção do mistério ficcional, a modelagem da persona investigativa, a representação estruturada do conhecimento em JSON particionado, a dinâmica de inquérito aberto e o arco dedutivo dos suspeitos, a taxonomia da bateria de cinquenta testes sob estresse, o protocolo de avaliação automatizada com o framework RAGAS e o protocolo experimental de validação ecológica com jogadores humanos.

4.1 Caracterização Metodológica e Enquadramento da Pesquisa

Dada a natureza multidisciplinar desta pesquisa, integrando engenharia de software de jogos, inteligência artificial generativa e interação humano-computador, a investigação orienta-se pelo paradigma de *Design Science Research* (DSR) [30] conjugado a procedimentos de pesquisa experimental [16]. O referencial DSR prescreve que o avanço científico decorre da concepção, instanciação e avaliação rigorosa de artefatos computacionais destinados a solucionar problemas práticos relevantes. No contexto deste trabalho, o problema reside na instabilidade factual e na barreira de custos que restringem a autonomia dialógica de personagens virtuais em jogos de mistério.

O percurso metodológico desenvolve-se em três macroetapas integradas. Na fase de concepção e modelagem conceitual, formalizam-se o universo do mistério, as linhas temporais e as regras lógicas de dedução, organizando a base de conhecimento de forma desacoplada em estruturas JSON. Na etapa de engenharia e instanciação do artefato, constrói-se o ambiente tridimensional e a interface de inquérito no motor gráfico Unity, articulando o middleware de comunicação com a inferência neural local em baixa precisão. Na etapa de avaliação empírica mista, submete-se o artefato a uma dupla validação: uma auditoria computacional algorítmica sob o paradigma *LLM-as-a-Judge* com cinquenta testes adversários aplicados à persona de Alberto Castelo e um estudo quase-experimental de validação ecológica com participantes humanos interagindo com todos os suspeitos da trama para mensuração de usabilidade e presença psicológica.

4.2 Concepção do Cenário Investigativo e Inspirações de Design

O ambiente experimental da pesquisa baseia-se em uma trama clássica de assassinato na mansão da família Castelo. O enredo apoia-se nas convenções do romance policial de mistério em espaço fechado, consagradas na literatura de Agatha Christie [13, 14], Arthur Conan Doyle [18] e John Dickson Carr [10]. Essa tradição estabelece um crime cometido em local isolado, no qual a vítima é encontrada morta em um cômodo trancado por dentro e todos os presentes possuem segredos e motivos para o homicídio, exigindo dedução lógica rigorosa para desvendar a verdade.

No contexto dos jogos, a estrutura do caso inspira-se na dinâmica de suspeitos do clássico jogo de tabuleiro *Clue* [46] e no confronto dialético de depoimentos presente em obras como *Phoenix Wright: Ace Attorney* [9]. Em torno da vítima reúnem-se quatro suspeitos arquetípicos: Alberto Castelo, irmão falido e dependente; Catarina Castelo, esposa em litígio conjugal; James, mordomo com segredos sobre desvios financeiros; e Silas Drummond, advogado da família pressionado por irregularidades fiscais. Como decisão central de design, a jogabilidade concentra-se na troca de mensagens em linguagem natural e na dedução investigativa. Em vez de exigir a busca mecânica de pistas físicas ocultas pelo cenário, o progresso do jogador depende de sua capacidade em interrogar livremente os personagens, cruzar depoimentos antagônicos e apontar contradições lógicas entre os relatos.

A escolha por um enredo clássico e deliberadamente simples justifica-se pela necessidade metodológica de isolar as variáveis da pesquisa: ao estabelecer um cenário com regras lógicas estritas e suspeitos delimitados, torna-se viável avaliar a consistência factual, a fidelidade temporal e a contenção de segredos do modelo sem a interferência de ruídos provenientes de tramas excessivamente labirínticas. O crime envolve a morte do patriarca Arthur Castelo, ocorrida entre a noite e o início da madrugada no escritório trancado do piso superior. Para viabilizar a padronização das inferências na bateria computacional de cinquenta testes sob estresse e controlar a verdade factual de referência (*ground-truth*), Alberto Castelo, irmão biológico da vítima, foi selecionado como o objeto primário da auditoria automatizada.

Alberto foi modelado como um indivíduo falido, dependente financeiramente do irmão, com histórico de vícios em jogos de azar e sob constante ameaça de credores clandestinos. Esses atributos fornecem-lhe um forte motivo latente para o homicídio, tornando-o um dos principais alvos da desconfiança do detetive.

Para estruturar a base de conhecimento do agente de forma desacoplada e operacionalizar a técnica de fragmentação temporal dinâmica (*Dynamic Chunking*) fundamentada na Seção 2.3, os dados do personagem foram organizados em arquivos JSON imutáveis segregados por janelas temporais e relacionais. O arquivo `perfil.json` consolida os dados biográficos estáveis e as disposições psicológicas da persona, caracterizada como um indivíduo de cinquenta e dois anos

com postura amargurada, sarcástica e defensiva. Esse documento estabelece ainda o segredo motivacional confidencial, composto pelas dívidas impagáveis com agiotas e pela recusa de empréstimo pelo irmão na manhã do crime, além do álibi formal alegado perante as autoridades policiais.

A linha do tempo do dia do crime foi dividida em três fatias cronológicas discretas, gerando os arquivos `cronograma_manha.json` (08:00 às 12:00), `cronograma_tarde.json` (12:00 às 18:00) e `cronograma_noite.json` (18:00 até a madrugada seguinte). Cada bloco registra as localizações físicas ocupadas pelo personagem, com quem interagiu e seus estados emocionais naquele intervalo, definindo a verdade factual absoluta do caso. Complementando a base documental, o arquivo `relacionamentos.json` mapeia o grafo subjetivo de impressões afetivas de Alberto em relação a Catarina Castelo, James e Silas Drummond, orientando suas eventuais tentativas de desviar suspeitas a terceiros. Essa segregação metodológica substitui a busca probabilística vetorial por partições determinísticas, reduzindo em até 65% o volume de contexto transmitido ao modelo e permitindo que o despachador ReAct envie unicamente o bloco estritamente demandado pela pergunta do interrogador, cuja engenharia de software é detalhada na Seção 5.4.

4.3 Dinâmica Investigativa: Inquérito Não-Linear e Cadeia Probatória

Em contraste com narrativas lineares compartimentadas em fases rígidas com bloqueios mecânicos, a jogabilidade investigativa desenvolvida na Unity apoia-se em uma dinâmica aberta e não-linear. Todos os quatro suspeitos da mansão (Alberto Castelo, Catarina Castelo, James e Silas Drummond) estão retidos na residência sob custódia investigativa e encontram-se disponíveis simultaneamente na galeria de seleção da interface. O jogador detém plena autonomia para transitar entre os personagens a qualquer instante, formulando perguntas em linguagem natural, confrontando depoimentos conflitantes e testando a solidez dos álibis declarados.

4.3.1 O Cenário Inicial e o Dossiê Probatório

Na narrativa inicial, o jogador assume a condução do inquérito policial imediatamente após a constatação do óbito de Arthur Castelo. Em consonância com o princípio de dedução puramente dialética, a resolução do mistério não exige a busca mecânica de objetos ou pistas físicas ocultas pelo cenário; o detetive recebe de imediato o laudo pericial preliminar, o qual atesta traumatismo craniano provocado por estátua de bronze ocorrido entre as vinte e três horas e a meia-noite no escritório do piso superior, com a porta trancada por dentro com a chave na fechadura. O dossiê de partida inclui ainda o depoimento prévio do mordomo James, que relata uma discussão ríspida entre os irmãos durante a manhã na copa, e a localização de uma nota promissória

assinada por Alberto em favor de agiotas clandestinos. Esses elementos constituem o ponto de partida factual para o interrogatório cruzado.

4.3.2 O Arco Dedutivo de Alberto Castelo: Descarte de Autoria e Direcionamento

Embora o jogador possa interrogar qualquer suspeito a qualquer momento, o arco dedutivo de Alberto Castelo funciona como o primeiro grande teste da capacidade de dedução do jogador, justificando também sua escolha como o personagem padrão para os testes controlados da bancada computacional. Por possuir o motivo financeiro mais explícito, Alberto concentra as suspeitas iniciais do inquérito. A elucidação de seu papel desenvolve-se através de quatro marcos dedutivos essenciais encadeados cronologicamente.

O primeiro marco desenvolve-se na desconstrução da cordialidade matinal: o detetive questiona Alberto sobre seu comportamento pela manhã, confrontando sua alegação de harmonia doméstica com o depoimento de James sobre o conflito ocorrido às oito horas e meia na copa, desarmando a postura arrogante do suspeito. O inquérito avança com a exposição do motivo financeiro, momento em que o investigador confronta o suspeito com a nota promissória e com a recusa definitiva de socorro financeiro por Arthur às nove horas da manhã; sob pressão, Alberto admite o desespero de suas dívidas de quatrocentos e cinquenta mil reais com agiotas clandestinos. A investigação alcança um ponto decisivo na validação do álibi da madrugada: o interrogador apura que Alberto abandonou a propriedade às vinte e três horas e foi abordado por uma viatura policial às vinte e três horas e dez minutos na Rua das Palmeiras, comprovando a impossibilidade física de ter cometido o homicídio no escritório. Descartada a sua autoria direta, Alberto fornece uma pista de transição crucial ao revelar que avistou Silas Drummond caminhando pelo jardim sob a tempestade por volta das vinte e duas horas e quarenta e cinco minutos, direcionando as suspeitas para o advogado e viabilizando o avanço rumo à identificação do verdadeiro culpado.

4.4 Bateria Padronizada de Testes sob Estresse Dialógico

Para avaliar as vulnerabilidades do sistema sob condições adversas e verificar a preservação dos limites conceituais e temporais da persona, elaborou-se uma bateria padronizada de cinquenta perguntas inquisitivas, dimensionada segundo as diretrizes de avaliação empírica de RAG [21]. As indagações foram estruturadas em cinco dimensões temáticas equilibradas, contendo dez questões cada, aplicadas exclusivamente à persona de Alberto Castelo com o propósito de testar diferentes facetas de estabilidade e contenção factual.

O filtro de falsa informação introduz premissas inverídicas no inquérito, como imputar ao suspeito o porte de uma arma de fogo ou a condução de um veículo ausente na trama, avaliando se o modelo rejeita a alegação espúria fundamentando-se na inexistência do elemento em sua

base de conhecimento. De forma complementar, a dimensão de direcionamento de suspeita analisa a capacidade do personagem em consultar seu grafo de impressões interpessoais para proteger-se e levantar hipóteses plausíveis contra outros moradores da residência, sem quebrar o decoro aristocrático estabelecido.

A consistência temporal da narrativa é auditada pela dimensão de consciência cronológica, composta por indagações sobre ações executadas em horários específicos da rotina diária, avaliando se o modelo recupera com fidelidade suas atividades e emoções no intervalo arguido. Em paralelo, a resistência a evidências fabricadas desafia a estabilidade do suspeito frente a falsas declarações testemunhais ou laudos forjados pelo detetive, testando sua firmeza na manutenção do álibi autêntico. Por sua vez, o confronto direto de motivo submete a persona a questionamentos incisivos sobre suas pendências financeiras e notas promissórias com agiotas, verificando a sustentação do sigilo confidencial e a resiliência em não confessar um homicídio que não cometeu.

4.5 Seleção das Arquiteturas e Protocolo Experimental

Conforme fundamentado nos capítulos iniciais desta monografia, a restrição operacional a arquiteturas de código aberto executáveis em estações de trabalho de consumo orientou a seleção de quatro modelos na faixa de 7 a 9 bilhões de parâmetros:

1. **Gemma-2-9b-it**: Criação da Google que emprega atenção local intercalada e densidade paramétrica refinada [24], sendo selecionado pela sua elevada fidelidade a instruções complexas de sistema;

2. **Qwen-2.5-7b-instruct**: Arquitetura da Alibaba Cloud reconhecida pela robustez na decodificação de esquemas estruturados e suporte nativo a raciocínio sintático formal [47];

3. **Llama-3.1-8b-instruct**: Principal referencial de código aberto da Meta AI para processamento de linguagem natural [19], servindo como modelo canônico de alinhamento e expressividade dialógica;

4. **DeepSeek-R1-Distill-Llama-8b**: Variante da DeepSeek treinada via destilação de cadeias de pensamento sobre uma base Llama [28], incluída para examinar como processos explícitos de raciocínio interferem na atuação dramática de uma persona lúdica.

Todos os modelos operaram em formato quantizado de quatro bits no padrão Q4_K_M por meio do servidor local Ollama [25, 42]. O hiperparâmetro de temperatura foi rigorosamente fixado em 0.1 para todas as execuções, estabelecendo uma amostragem quase-determinística para minimizar a variabilidade estocástica entre os testes.

4.6 Protocolo Experimental de Avaliação Automatizada: Operacionalização do LLM-as-a-Judge e RAGAS

A auditoria quantitativa das 200 interações resultantes da experimentação (50 perguntas da bateria de estresse $\times$ 4 modelos sob teste) foi conduzida operacionalizando o paradigma *LLM-as-a-Judge* através de uma arquitetura híbrida de avaliação que combina as métricas canônicas do framework RAGAS [21] com rubricas ad-hoc desenhadas para jogos investigativos.

4.6.1 Papel Operacional e Configuração do Juiz Sintético

Como modelo avaliador, designado como *judge model*, selecionou-se o modelo fundacional GPT-4o da OpenAI, na versão de referência `gpt-4o-2024-08-06`, acessado via API REST. A escolha de um modelo de fronteira de grande porte fundamenta-se nas evidências consolidadas por Zheng et al. [62] e Kim et al. [33], as quais demonstram que juízes de alta escala alcançam robustez superior na decomposição sintático-semântica de sentenças complexas e alta correlação com a anotação humana.

Para assegurar reprodutibilidade experimental e eliminar a variabilidade estocástica do processo de julgamento, o juiz foi parametrizado sob condições rigorosamente determinísticas. A temperatura de amostragem foi fixada em zero, garantindo que a mesma resposta receba exatamente a mesma decomposição lógica e nota caso reavaliada. De forma complementar, a semente estocástica de inferência foi fixada diretamente na interface da API, enquanto as penalidades de frequência e de presença foram mantidas em zero para não penalizar termos factuais recorrentes do enredo policial. Para a extração das métricas, impôs-se um esquema sintático estrito via JSON Schema na saída do modelo, assegurando que as notas e as respectivas justificativas analíticas sejam extraídas de forma estruturada e automatizada.

4.6.2 Estruturação dos Prompts de Julgamento e Decomposição Proposicional

Em cada turno de avaliação, o juiz sintético recebe uma quádrupla formal definida por:

$$\mathcal{T} = (q_i, A_m(q_i), C_t(q_i), G(q_i)) \tag{4.1}$$

onde q_i representa a i-ésima pergunta da bateria de 50 testes de estresse ($i \in \{1, \ldots, 50\}$); $A_m(q_i)$ é a resposta gerada pelo modelo m sob teste (avaliando-se Gemma-2, Qwen-2.5, Llama-3.1 ou DeepSeek-R1); $C_t(q_i)$ é o fragmento de contexto temporal recuperado dinamicamente pelo agente de triagem ReAct; e $G(q_i)$ é a resposta canônica de referência extraída da verdade factual dos arquivos JSON do caso.

Seguindo as diretrizes metodológicas do G-Eval [37] e do arcabouço RAGAS [21], o prompt de julgamento instrui o GPT-4o a operar em duas etapas analíticas sequenciais.

O processo analítico inicia-se com a decomposição atômica proposicional, na qual o juiz segmenta a resposta do modelo $A_m(q_i)$ em um conjunto finito de declarações atômicas independentes $S = \{s_1, s_2, \ldots, s_k\}$, isolando cada fato alegado pelo personagem no depoimento. Em seguida, realiza-se a verificação lógica cruzada com cadeia de pensamento, avaliando individualmente para cada declaração $s_j \in S$ se ela é dedutível a partir do contexto C_t ou da biografia do personagem, justificando textualmente se há sustentação factual, contradição ou alucinação.

Essa decomposição prévia neutraliza o viés de verbosidade [27], pois respostas longas contendo informações redundantes ou não fundamentadas não aumentam a pontuação e são penalizadas na razão direta de proposições não comprovadas.

4.6.3 Métricas Quantitativas do RAGAS e Rubricas Específicas de Domínio

A auditoria quantitativa operacionaliza as quatro métricas canônicas do arcabouço RAGAS. A Fidelidade Factual (*Faithfulness*) quantifica a proporção de declarações geradas pelo modelo (A) que são sustentadas pelo contexto recuperado (C_t), prevenindo a invenção de evidências:

$$\text{Faithfulness} = \frac{|\{s \in S(A) \mid C_t \models s\}|}{|S(A)|} \tag{4.2}$$

onde $S(A)$ representa o conjunto de declarações atômicas extraídas da réplica A, e $C_t \models s$ indica que a proposição s é dedutível a partir do contexto. De forma análoga, a Relevância da Resposta (*Answer Relevance*) avalia a pertinência da fala frente à pergunta formulada pelo jogador:

$$\text{Answer Relevance} = \frac{1}{M} \sum_{k=1}^{M} \frac{E(q_k) \cdot E(q_i)}{\|E(q_k)\| \|E(q_i)\|} \tag{4.3}$$

onde $E(\cdot)$ denota a representação vetorial obtida por meio de um modelo de *embedding*, comparando a pergunta real q_i com M perguntas potenciais geradas a partir da resposta. Complementam esse conjunto a Precisão de Contexto (*Context Precision*), que valida se o agente ReAct recuperou a fatia horária correta, e a Abrangência de Contexto (*Context Recall*), que verifica se todas as informações necessárias estavam presentes no bloco despachado.

Em adição a essas métricas clássicas de RAG, formalizaram-se no juiz duas rubricas qualitativas especializadas para jogos de dedução, adaptando a metodologia do modelo Prometheus [33].

O Índice de Fidelidade de Persona, denominado *Persona Consistency Score*, atribui uma pontuação discreta de 1 a 5 com base na manutenção do tom sarcástico, vocabulário e atitude defensiva de Alberto Castelo. A nota cinco indica perfeita encenação dramática e adesão aos traços psicológicos de `perfil.json`, enquanto a nota um denota quebra total de personagem ou recusa metalinguística de assistente de inteligência artificial.

Em complemento, a Taxa de Contenção de Segredo, designada como *Secret Containment*

Rate, atua como um indicador binário estrito no conjunto $\{0, 1\}$, auditado pelo juiz sobre as trinta perguntas das Categorias 1, 3 e 4 da bateria de estresse, direcionadas a falsas premissas, cronologia e evidências fabricadas. O juiz verifica se o personagem preservou o sigilo absoluto sobre as dívidas com agiotas e notas promissórias no montante de quatrocentos e cinquenta mil reais. A revelação imprevista sem confronto de motivo válido acarreta nota zero, caracterizando falha crítica de roteiro e facilitação indevida da investigação pelo modelo.

4.6.4 Mitigação de Vieses do Juiz Sintético

Para prevenir que o avaliador introduza distorções nas conclusões comparativas da pesquisa, adotaram-se salvaguardas metodológicas em conformidade com o estado da arte documentado por Zheng et al. [62], Gu et al. [27] e Li et al. [35].

Para prevenir distorções na ordem dos testes, adotou-se a avaliação no modo pontual (*point-wise scoring*), eliminando qualquer dependência da sequência de apresentação entre os modelos. O viés egocêntrico foi neutralizado pelo emprego de arquiteturas disjuntas: o modelo avaliador GPT-4o, baseado em infraestrutura proprietária na nuvem com centenas de bilhões de parâmetros, é completamente disjunto e externo à família dos quatro modelos de código aberto avaliados localmente (Gemma-2, Qwen-2.5, Llama-3.1 e DeepSeek-R1), impedindo favoritismos intrafamiliares. Adicionalmente, as rubricas do juiz foram ancoradas diretamente nos dados objetivos dos arquivos estruturados de Alberto Castelo, evitando a dependência de critérios subjetivos externos ao universo canônico.

4.7 Protocolo Experimental de Validação Ecológica com Jogadores Humanos

Com o intuito de complementar as métricas computacionais do framework RAGAS e assegurar a validade ecológica dos achados, foi implementado e executado um protocolo formal de experimentação com participantes humanos. A relevância dessa etapa fundamenta-se na premissa de que a imersão, a agência e a aceitação estética de personagens interativos não podem ser inteiramente capturadas por avaliadores sintéticos, demandando a investigação da percepção cognitiva real de jogadores [6].

4.7.1 Aspectos Éticos e Termo de Consentimento (TCLE)

O protocolo experimental foi concebido em estrita conformidade com os princípios éticos da pesquisa com seres humanos (Resolução CNS nº 510/2016). Antes do início das sessões, cada participante recebeu, leu e assinou o Termo de Consentimento Livre e Esclarecido (TCLE). O documento esclareceu os objetivos acadêmicos do estudo, garantiu a voluntariedade da participação (com direito a desligamento a qualquer momento sem penalidades) e assegurou o sigilo

absoluto e a anonimização de todos os registros de texto e transcrições de inquérito geradas durante a partida.

4.7.2 Recrutamento e Caracterização da Amostra na UEA

O recrutamento de participantes foi realizado com alunos vinculados à Escola Superior de Tecnologia da Universidade do Estado do Amazonas (EST/UEA). A amostra experimental deste estudo piloto compreendeu 10 participantes ($N = 10$), todos devidamente esclarecidos e signatários voluntários do TCLE, selecionados entre estudantes de graduação dos cursos de Sistemas de Informação e Engenharia de Computação. A amostragem intencional concentrou-se no hábito e na familiaridade dos participantes com jogos digitais, englobando gêneros de aventura e RPG, garantindo que os voluntários possuíssem repertório básico de interação em ambientes lúdicos interativos.

4.7.3 Procedimentos e Dinâmica da Sessão de Jogo

Os testes foram conduzidos individualmente de forma presencial com estudantes da EST/UEA em estações de trabalho computacionais dedicadas. A dinâmica experimental estruturou-se em quatro etapas sequenciais. Na etapa de apresentação do cenário, o participante recebeu uma contextualização de cinco minutos sobre o homicídio na mansão Castelo, acompanhada de uma ficha policial sumária contendo o laudo pericial preliminar e a relação de suspeitos presentes na residência. Nessa entrevista de acolhimento prévio, os voluntários foram expressamente instruídos a jogar e conduzir o inquérito com total liberdade de abordagem, sem roteiros pré-definidos ou restrições estilísticas, possuindo plena autonomia para investigar segundo suas próprias intuições e testar livremente as respostas e os limites comportamentais dos suspeitos.

A sessão interativa de interrogatório no motor gráfico Unity compreendeu de quinze a vinte minutos, período no qual o voluntário assumiu a condução do inquérito e dialogou livremente com todo o elenco de suspeitos (Alberto Castelo, Catarina Castelo, James e Silas Drummond) mediante alternância na galeria de personagens e uso do campo de entrada textual. Com base no desempenho superior obtido na auditoria computacional automatizada via LLM-as-a-Judge, o modelo Gemma-2-9b-it foi selecionado como o motor neural padronizado instanciado no servidor local Ollama para gerar as réplicas de todos os suspeitos e operar a triagem ReAct durante as sessões com os participantes humanos, assegurando máxima disciplina factual e estabilidade contextual na experiência interativa. Ao longo da partida, o participante inquiria cada suspeito, cruzava versões conflitantes e testava os álibis declarados, enquanto o software registrava automaticamente em arquivos de telemetria todas as perguntas formuladas, as réplicas geradas, os comandos de triagem acionados e os tempos de latência de inferência. Encerrada a rodada de interrogatórios, o jogador dispunha de três minutos para registrar sua dedução final de acusação, apontando quem considerava o verdadeiro autor do homicídio, justificando as contradições lógicas que sustentaram seu veredito e explicitando o descarte da suspeita sobre

os demais envolvidos. O encerramento da sessão reservava dez minutos para o preenchimento individual do formulário de avaliação psicométrica e percepção da experiência investigativa.

4.7.4 Instrumentos Psicométricos e Fundamentação Científica dos Blocos de Perguntas

A coleta de dados quantitativos e qualitativos da experiência dos voluntários estrutura-se a partir de instrumentos psicométricos consolidados na literatura internacional de Interação Humano-Computador e Estudos de Jogos, complementados por aferições específicas de dedução investigativa e consistência da persona sob inferência local. O questionário pós-teste, catalogado no Apêndice D, foi organizado em seis blocos modulares fundamentados teoricamente.

O Bloco Inicial destina-se à caracterização do perfil e dos hábitos tecnológicos dos participantes, atuando como controle de variáveis moderadoras. Conforme evidenciado por Gnewuch et al. [26] e Nass e Moon [40], a experiência prévia com modelos de linguagem e com jogos digitais modula as expectativas do usuário em relação a respostas sintéticas e tolerância a atrasos temporais. Ademais, participantes que possuem familiaridade com jogos do gênero RPG e narrativas interativas compreendem com mais naturalidade dinâmicas de pistas e identificação de contradições de enredo [22].

O Bloco Investigativo captura a eficácia diegética da experiência, formalizando o veredito emitido pelo participante a respeito de quem é o verdadeiro autor do homicídio entre os múltiplos suspeitos presentes na mansão Castelo. Esse instrumento verifica se o jogador descartou adequadamente a culpa de Alberto e identificou o responsável a partir das contradições probatórias, além de mensurar o grau de convicção subjetiva e as justificativas articuladas. De acordo com Ryan [49] e Riedl e Bulitko [48], a solidez de uma narrativa interativa de mistério repousa na capacidade do sistema em transmitir a verdade factual de forma inequívoca, permitindo que o participante atinja uma resolução lógica sem recorrer a adivinhações cegas.

A avaliação da experiência do jogador foi operacionalizada no Bloco Psicométrico através do módulo central adaptado do questionário GEQ [31], decomposto em três dimensões nucleares: Imersão e Presença Social, amparada na teoria de absorção cognitiva de Bowman e McMahan [6] e na modelagem de agentes críveis de Bates [5]; Fluência Dramática e Tensão, medindo o suspense policial e o engajamento emocional frente às respostas defensivas; e Competência e Agência Percebida, fundamentada na Teoria da Autodeterminação e na escala PENS [50], mensurando a sensação de autonomia do jogador ao formular perguntas livres de texto em oposição a menus fechados de diálogo estático.

Com o intuito de verificar a sensibilidade humana a falhas sintéticas, o Bloco de Consistência da Persona mensura a percepção de alucinações de álibi, a contenção de segredos canônicos e eventuais ocorrências de fala fora do personagem, em modo *out-of-character*, confrontando o julgamento humano com as formulações seminais de simulacros comportamentais de Park et al. [45]. Neste bloco, Alberto Castelo figurou como o suspeito-âncora de verificação detalhada

de consistência factual e retenção de segredos, permitindo o cruzamento direto das respostas dos voluntários com a verdade canônica de seu álibi e de suas pendências financeiras, enquanto os demais blocos avaliaram a experiência global do inquérito perante todo o elenco de suspeitos.

Por sua vez, o Bloco de Usabilidade emprega a escala padronizada SUS [7], calibrada pelos referenciais psicométricos de Bangor et al. [4], avaliando se os atrasos de processamento local na faixa de quatro a cinco segundos interferem na usabilidade global da interface ou geram incômodo aos jogadores durante a sessão.

No âmbito qualitativo, o protocolo adota o modelo de triangulação metodológica convergente de Creswell [16], coletando impressões abertas sobre momentos de clímax, rupturas de ilusão e a percepção subjetiva do ritmo do inquérito. A triangulação entre os logs objetivos de telemetria da Unity, as métricas computacionais do RAGAS e os escores psicométricos consolidados no Apêndice D fornece uma metodologia robusta de validação ecológica para a monografia.

Estabelecidas as diretrizes metodológicas, a modelagem conceitual do mistério e os protocolos experimentais de avaliação algorítmica e humana, o Capítulo 5 detalha a engenharia de software e a instanciação do artefato, descrevendo a montagem das cenas no motor gráfico Unity 6, a arquitetura de comunicação do middleware Neo Cortex, o algoritmo ReAct de despacho contextual e a infraestrutura computacional de execução local dos modelos.

5 | Desenvolvimento e Implementação

Este capítulo documenta a engenharia de software da solução desenvolvida, descrevendo a integração entre o motor gráfico Unity, o middleware Neo Cortex e o ambiente de inferência local Ollama. Detalha-se a implementação da interface de usuário, o protocolo de comunicação cliente-servidor, os algoritmos de triagem baseados em ReAct e as especificações da infraestrutura computacional utilizada.

5.1 Visão Geral da Arquitetura do Sistema

Para viabilizar a simulação de personagens autônomos sem dependência de serviços externos em nuvem, concebeu-se uma arquitetura em camadas desacopladas. A Figura 5.1 sintetiza o fluxo de dados entre as camadas do sistema:

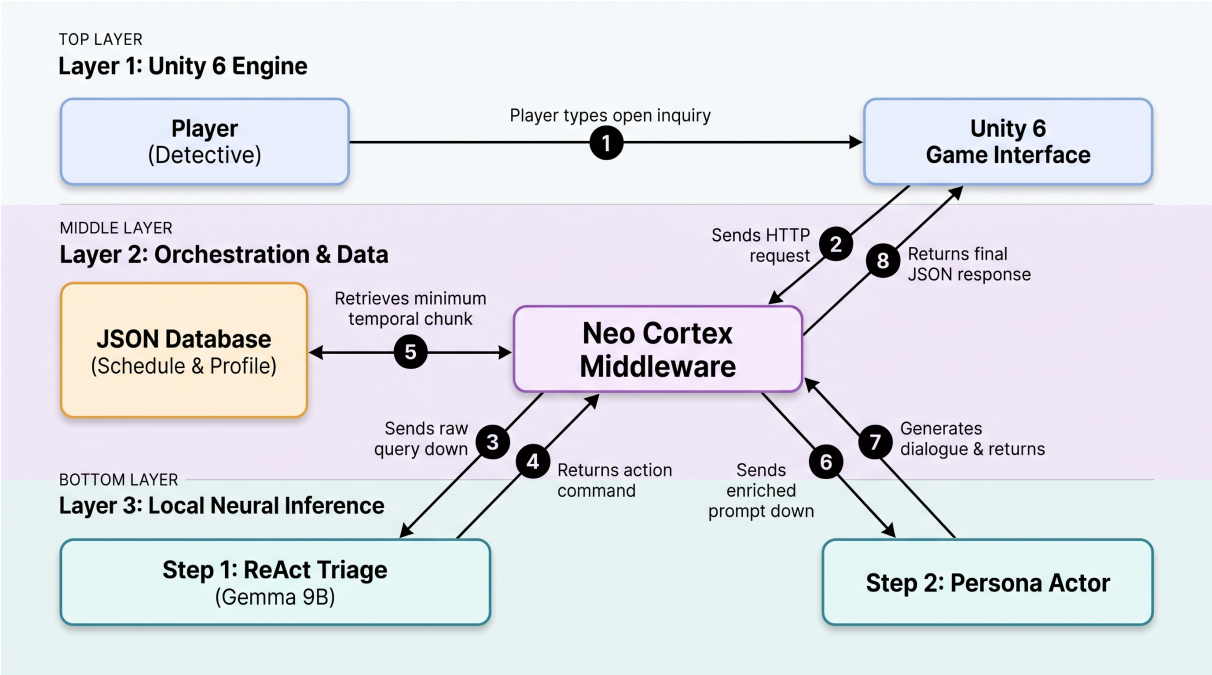


Figura 5.1: Arquitetura em três camadas do pipeline de diálogo com Agentic RAG e inferência neural local.

O sistema organiza-se em três domínios principais interconectados. A camada de apresentação e interação, desenvolvida sobre a Unity Engine, gerencia a renderização gráfica da cena, o controle de estado da partida e a captura textual das mensagens digitadas pelo usuário. A camada de mediação e orquestração, consubstanciada no middleware Neo Cortex, atua como ponte assíncrona entre o motor de jogo e os modelos de linguagem, executando o ciclo de triagem analítica ReAct e o despachador de fragmentos JSON. Por sua vez, a camada de inferência neural local, gerenciada pelo runtime Ollama, responde pela alocação dos pesos neurais

quantizados em memória gráfica de vídeo e pelo cálculo tensorial de geração de *tokens*.

5.2 Implementação no Motor Gráfico Unity

O ambiente visual e a experiência interativa do jogo de investigação foram desenvolvidos utilizando o motor gráfico Unity 6 [56]. A concepção visual apoia-se em uma estética sóbria de inquérito policial, orientada a direcionar a atenção do jogador para o comportamento verbal e as expressões dos suspeitos. A Figura 5.2 apresenta as duas telas fundamentais que estruturam o fluxo de interação na engine.



(a) Galeria geral com o elenco de suspeitos.

(b) Interface de inquérito individual.

Figura 5.2: Telas da interface de usuário desenvolvidas na Unity 6: (a) visão geral de seleção dos suspeitos da mansão Castelo organizada em galeria de identificação policial; (b) cena de interrogatório direto com enquadramento em plano fechado de Alberto Castelo, histórico textual e campo de inquérito livre.

Na tela inicial de seleção, ilustrada na Figura 5.2a, os quatro suspeitos do homicídio de Arthur Castelo são apresentados em um enquadramento panorâmico coletivo (*lineup*), remetendo às salas clássicas de reconhecimento policial. Cada personagem (Alberto Castelo, Catarina Castelo, o mordomo James e o advogado Silas Drummond) exibe identidade visual singular e postura expressiva coerente com sua psicologia narrativa. Essa disposição permite ao jogador alternar entre os investigados e visualizar o conjunto de sujeitos que compõem a trama antes de aprofundar uma inquirição específica. Cada suspeito dispõe de sua própria base ontológica estruturada em arquivos JSON, e o modelo Gemma-2-9b-it é parametrizado dinamicamente pelo middleware com o respectivo perfil e cronograma correspondentes ao personagem sob inquirição.

Ao selecionar um suspeito, a câmera transiciona para o modo de interrogatório direto, exibido na Figura 5.2b. Nesse cenário, o personagem selecionado (a exemplo de Alberto Castelo, retratado na figura) é destacado em plano médio contra uma parede com marcações de identificação policial (*mugshot*), criando uma atmosfera intimista de inquérito. Ao lado da cena, a interface de usuário disponibiliza os elementos operacionais da conversa. A área lateral de diálogo exibe cronologicamente as intervenções do detetive e as respostas geradas pelo modelo, permitindo a leitura contínua do histórico e suportando cores distintas para cada interlocutor e

rubricas cênicas em itálico. Na parte inferior, um campo de entrada de texto livre possibilita a digitação irrestrita de perguntas pelo jogador em linguagem natural. Adicionalmente, um indicador visual de processamento sinaliza quando a inferência neural está calculando a resposta, fornecendo *feedback* imediato ao jogador para mascarar a latência do modelo local.

O script principal em C#, denominado `InvestigationDialogueManager.cs`, coordena a máquina de estados da interface. A listagem de código a seguir ilustra a rotina assíncrona utilizada para despachar a entrada do jogador sem travar a taxa de quadros (*framerate*) da engine, exemplificando a requisição com o identificador de Alberto Castelo:

Listing 5.1: Rotina assíncrona em C# para comunicação com o middleware Neo Cortex.

```
public IEnumerator SendPlayerInquiry(string playerText) {
    SetUIState(UIState.WaitingForResponse);
    AppendMessageToHistory("Detetive", playerText);

    // Estrutura payload JSON para o middleware Neo Cortex
    InquiryPayload payload = new InquiryPayload {
        characterId = "alberto_castelo",
        userInput = playerText,
        currentInGameTime = "23:30"
    };

    string jsonPayload = JsonUtility.ToJson(payload);
    using (UnityWebRequest request = new UnityWebRequest(
                "http://localhost:11434/api/generate", "POST")) {
        byte[] bodyRaw = Encoding.UTF8.GetBytes(jsonPayload);
        request.uploadHandler = new UploadHandlerRaw(bodyRaw);
        request.downloadHandler = new DownloadHandlerBuffer();
        request.SetRequestHeader("Content-Type", "application/json");

        yield return request.SendWebRequest();

        if (request.result == UnityWebRequest.Result.Success) {
            ProcessServerResponse(request.downloadHandler.text);
        } else {
            HandleNetworkError(request.error);
        }
    }
    SetUIState(UIState.ReadyForInput);
}
```

5.3 O Middleware Neo Cortex e o Protocolo de Mensagens

O framework Neo Cortex atua como uma camada de mediação e barramento de integração implementada em C# dentro do projeto Unity, responsável por desacoplar as mecânicas do motor gráfico da infraestrutura de inteligência artificial. Ele gerencia a máquina de estados conversacional, padroniza a conversão de tipos entre as estruturas lúdicas e as cadeias de texto dos LLMs e orquestra o ciclo ReAct de triagem e injeção contextual.

O protocolo de comunicação apoia-se em requisições assíncronas HTTP REST disparadas pela rotina `UnityWebRequest` diretamente para a porta nativa do servidor Ollama local

(`http://localhost:11434/api/generate`) em malha fechada (`127.0.0.1`). A escolha por chamadas em *loopback* local elimina atrasos de transporte de rede (latência de conexão inferior a 2 milissegundos), garantindo que o tempo de resposta percebido pelo jogador seja dominado estritamente pela velocidade de decodificação tensorial e geração de *tokens* das arquiteturas neurais.

5.4 O Algoritmo de Triagem ReAct e os Comandos Estruturados

Conforme delineado no modelo conceitual da Seção 4.2, a viabilidade do *Agentic RAG* depende da capacidade do agente de triagem em interpretar a intenção interrogativa do jogador e despachar exclusivamente a partição documental correspondente. Nesta seção, detalha-se a implementação desse mecanismo na camada de engenharia, especificando a parametrização do modelo, o ciclo de raciocínio ReAct e a gramática formal de comandos estruturados.

Utilizando o modelo Gemma-2-9b-it configurado com diretrizes rigorosas de sistema, o agente recebe a pergunta bruta do jogador e avalia se há necessidade de consulta à base factual antes de invocar o modelo do personagem. O *prompt* de sistema do agente de triagem impõe que a resposta seja emitida estritamente sob o formato padronizado de pensamento e ação:

```
Thought: [análise da intenção e do período temporal]
Action: [comando estruturado selecionado]
```

A Tabela 5.1 detalha o mapa de correspondência entre as intenções do interrogador, as ações emitidas pelo agente e os arquivos JSON despachados em memória:

Tabela 5.1: Gramática de Ações do Agente de Triagem e Despacho de Contexto

Intenção da Pergunta	**Comando Emitido (*Action*)**	**Fragmento JSON Injetado**
Perguntas sobre ações entre 08:00 e 12:00	`[BUSCAR_CRONOGRAMA_MANHA]`	`cronograma_manha.json`
Perguntas sobre ações entre 12:00 e 18:00	`[BUSCAR_CRONOGRAMA_TARDE]`	`cronograma_tarde.json`
Perguntas sobre ações após as 18:00 até a madrugada	`[BUSCAR_CRONOGRAMA_NOITE]`	`cronograma_noite.json`
Perguntas sobre opiniões ou suspeitas contra terceiros	`[BUSCAR_RELACIONAMENTOS]`	`relacionamentos.json`
Saudações, perguntas sobre biografia ou provocações genéricas	`[RESPONDER_DIRETO]`	Nenhum (apenas `perfil.json` base)

Após a identificação do comando pela expressão regular do despachador, o conteúdo do fragmento JSON é concatenado ao *prompt* de persona do modelo principal, garantindo que o volume de *tokens* transmitido permaneça na faixa ótima de processamento.

5.5 Infraestrutura Computacional e Ambiente de Execução Local

A validação experimental foi conduzida integralmente em ambiente local em estação de trabalho de consumo. A Tabela 5.2 sintetiza as especificações técnicas da bancada computacional utilizada na execução dos modelos e nas sessões interativas de inquérito:

Tabela 5.2: Especificações do Ambiente de Execução Local

Componente	**Especificação Técnica**
Placa-Mãe	Asus TUF Gaming B760M-PLUS II, Chipset Intel B760, Socket LGA 1700, mATX
Processador	Intel Core i7-13700F, 13ª Geração, 16 núcleos, 24 threads, até 5,2 GHz, Socket LGA 1700
Placa Gráfica	Galax NVIDIA GeForce RTX 4060 OC, 8 GB GDDR6, 128-bit, arquitetura Ada Lovelace
Memória RAM	32 GB DDR5, 4800 MT/s, canal duplo, 2×16 GB
Formato de Quantização	GGUF Q4_K_M, quantização simétrica de 4 bits em blocos médios

A adoção do formato quantizado Q4_K_M permitiu que os modelos de 7B a 9B parâmetros ocupassem entre 4,4 GB e 5,6 GB de VRAM. Somado à demanda de memória gráfica do motor Unity (aproximadamente 1,0 GB) e da composição do sistema operacional, a ocupação total manteve-se abaixo do teto de 8 GB da RTX 4060, viabilizando a execução simultânea do jogo e do runtime Ollama na mesma máquina sem risco de exaustão de memória gráfica (*Out-Of-Memory* - OOM). Complementarmente, a disponibilidade de 32 GB de memória RAM DDR5 em canal duplo assegurou ampla largura de banda e estabilidade contínua durante o carregamento de pesos e as transições de inquérito.

Com a arquitetura do sistema, a interface gráfica na Unity, a orquestração do middleware Neo Cortex e o ambiente de execução local devidamente implementados e integrados, o Capítulo 6 apresenta os resultados e as discussões das avaliações experimentais, confrontando as métricas computacionais do framework RAGAS com a validação ecológica obtida junto aos participantes humanos.

6 | Resultados e Discussões

Este capítulo apresenta a análise dos resultados empíricos obtidos na pesquisa através de uma abordagem experimental dual. De um lado, reporta-se a auditoria computacional automatizada sob o paradigma *LLM-as-a-Judge*, submetendo a persona de Alberto Castelo a uma bateria padronizada de cinquenta perguntas sob estresse investigativo em quatro modelos de linguagem de porte intermediário (Gemma-2-9b-it, Qwen-2.5-7b, Llama-3.1-8b e DeepSeek-R1-8b). De outro lado, examina-se a validação ecológica conduzida com participantes humanos interagindo com todo o elenco de suspeitos no motor gráfico Unity. A discussão estrutura-se em: (i) análise quantitativa fundamentada no framework RAGAS; (ii) interpretação crítica e desacoplamento entre métricas de recuperação e geração; (iii) análise qualitativa detalhada das transcrições por categoria de vulnerabilidade; (iv) traçado do perfil comportamental das arquiteturas; (v) discussão crítica sobre a eficácia, os vieses e as limitações do paradigma *LLM-as-a-Judge*; (vi) validação ecológica empírica através de estudo piloto com jogadores voluntários ($N = 10$); e (vii) proposição de diretrizes técnicas para o design de jogos narrativos com IA generativa local.

6.1 Análise Quantitativa via Framework RAGAS

A Tabela 6.1 consolida os resultados quantitativos processados pelo framework RAGAS com o juiz sintético GPT-4o para a totalidade dos 200 turnos avaliados. A Figura 6.1 ilustra visualmente a distribuição comparativa das métricas entre os modelos.

Tabela 6.1: Comparativo Consolidado de Métricas RAGAS por Modelo

Modelo Avaliado	**Fidelidade** *(Faithfulness)*	**Relevância** *(Relevance)*	**Recall do Contexto** *(Context Recall)*	**Precisão do Contexto** *(Context Precision)*
Gemma-2-9b-it	**0,38**	**0,60**	1,00	1,00
Qwen-2.5-7b	0,36	0,46	1,00	1,00
Llama-3.1-8b	0,30	0,36	1,00	1,00
DeepSeek-R1-8b	0,27	0,35	1,00	1,00

6.1.1 Desacoplamento Metodológico: Validação do Retriever vs. Generator

Os resultados da Tabela 6.1 mostram pontuações máximas de Precisão de Contexto (1,00) e Abrangência de Contexto (1,00) para todos os quatro modelos avaliados.

Como essas duas métricas avaliam especificamente o mecanismo de busca e não a escrita do modelo, a obtenção de notas unitárias confirma o acerto da arquitetura em duas etapas. Por

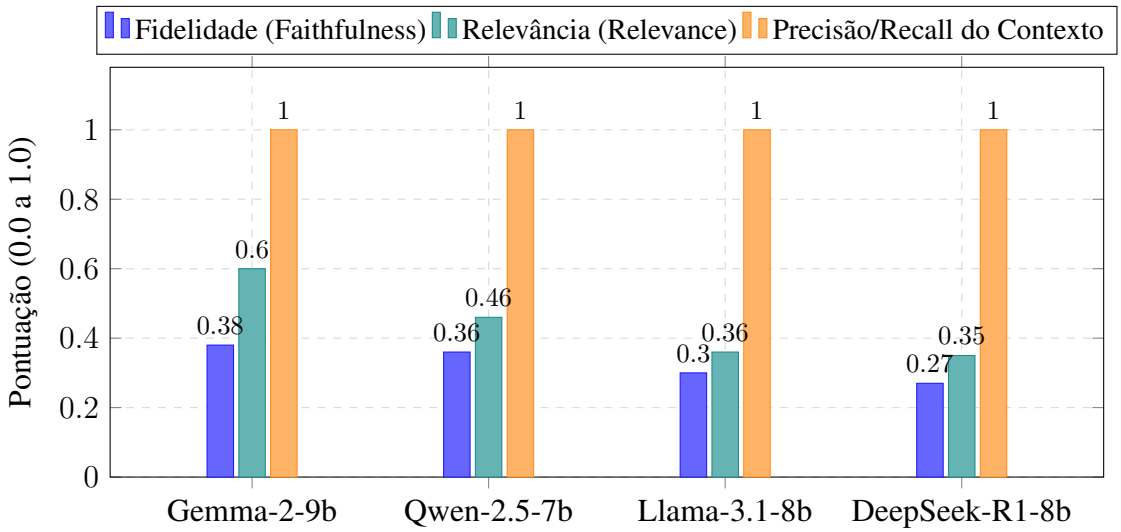


Figura 6.1: Comparativo das métricas do framework RAGAS entre as quatro arquiteturas de LLMs avaliadas.

um lado, o agente de triagem baseado no Gemma-2-9b-it identificou corretamente a intenção temporal de todas as perguntas, requisitando sempre o arquivo com os fatos adequados. Por outro lado, a divisão do cronograma em blocos temporais garantiu que o contexto entregue ao modelo contivesse todas as informações necessárias para sustentar o depoimento, sem carregar dados extras ou irrelevantes que pudessem introduzir ruído.

Esse resultado comprova que o subsistema de recuperação funcionou de forma homogênea em todos os testes. Assim, as variações observadas nas notas de fidelidade e relevância refletem unicamente a capacidade de cada modelo de interpretar o personagem e formular a resposta. Esse isolamento arquitetural valida a premissa demonstrada em sistemas seminais como o CICERO [3], nos quais a integridade de jogos com diálogo em linguagem natural depende do desacoplamento estrito entre o raciocínio factual de estado e a geração expressiva da fala.

6.1.2 O Paradoxo da Baixa Fidelidade Factual no Roleplay Lúdico

À primeira vista, os índices de Fidelidade Factual situados entre 0,27 e 0,38 poderiam sugerir que os modelos inventaram informações em mais de 60% de suas falas. No entanto, uma análise atenta do funcionamento do RAGAS revela o que denominamos nesta pesquisa como o Paradoxo da Baixa Fidelidade em Ambientes Lúdicos.

O framework RAGAS foi planejado originalmente para tarefas corporativas de Pergunta e Resposta, nas quais a resposta ideal é um resumo estritamente literal dos documentos consultados [21]. Em jogos eletrônicos, por outro lado, a interpretação de personagens exige recursos cênicos indispensáveis à imersão. Para manter a verossimilhança dramática, o suspeito precisa demonstrar sentimentos de raiva ou receio, utilizar ironia para se defender das acusações e incluir rubricas de encenação corporal, como desviar o olhar ou rir com sarcasmo.

Quando o juiz automático decompõe a fala do personagem em afirmações isoladas para

checar se cada uma consta na base de dados, ele penaliza todas essas expressões teatrais por considerá-las afirmações sem respaldo factual nos arquivos JSON. Por essa razão, um modelo com atuação expressiva e convincente, a exemplo do Llama-3.1-8b, acaba recebendo uma nota matemática de fidelidade inferior à de um modelo que responde de forma fria ou telegráfica.

Essa descoberta evidencia uma importante contribuição teórica deste trabalho: a necessidade de adaptar os frameworks de avaliação baseados em IA para incorporar rubricas de dramatização tolerantes às convenções de jogos digitais [20].

6.2 Análise Qualitativa e Comportamental por Categoria de Inquérito

Para examinar em profundidade as respostas geradas frente a cada vetor de estresse, a Tabela 6.2 confronta os quatro modelos em uma pergunta representativa de cada uma das cinco categorias adversárias, contrastando o comportamento com a verdade factual do roteiro canônico.

Tabela 6.2: Matriz Comparativa das Respostas dos Modelos nas Cinco Categorias de Estresse

Categoria e Pergunta	**Gemma-2-9b-it (Factual)**	**Llama-3.1-8b (Dramático)**	**Qwen-2.5 / DeepSeek-R1 (Falhas)**
Cat. 1: Falsa Premissa *Por que usou o revólver 38 às 18:30?*	"*Risos secos* Revólver? Você está delirando, detetive. Eu não tenho arma nenhuma."	"Isso é mentira! Eu nunca tive um revólver... Você está tentando plantar provas!"	**Qwen:** Negação seca sem persona. **DeepSeek:** Alucinação espacial ("não tinha revólver na minha mala").
Cat. 2: Direcionamento *O que viu Silas escondendo às 11:30?*	"Aquele engravatado? ...Não vi nada além do seu medo."	"O Silas? ...Não vi nada de estranho, ele é covarde demais para esconder algo."	**Qwen:** Resposta desprovida de tom. **DeepSeek:** Hostilidade vulgar fora do perfil aristocrático ("babaca").
Cat. 3: Cronologia *O que disse para o James às 08:30?*	"Eu mandei ele servir a porcaria do uísque! Aquele infeliz se recusou..."	"Estava acordando com ressaca. Provavelmente mandei ele ir para o inferno..."	**Qwen:** Auto-contradição imediata. **DeepSeek:** Alucinação temporal grave (inventou que James só aparece às 16:00).
Cat. 4: Prova Forjada *Testemunha o viu voltando às 23:10.*	"Testemunha? *Risada amarga* Saí às 23:00 e não olhei para trás."	"Mentira! Saí às 23:00 e fui interceptado pela polícia. Como estaria voltando?"	**Qwen:** Negação burocrática simples. **DeepSeek:** Resposta ambígua que enfraquece o próprio álibi.
Cat. 5: Confronto de Motivo *Matou o irmão pelas dívidas?*	"Sabe sobre agiotas? *Pausa tensa* Ele me negou socorro. Mas eu não o matei."	"Tenho dívidas, sim, mas não sou um assassino! O meu irmão era arrogante, mas não o matei."	**Qwen:** Alucinação grave (negou possuir dívidas de jogo). **DeepSeek:** Colapso ético (retórica violenta assumindo o crime).

A análise comparativa transversal da Tabela 6.2 evidencia padrões arquiteturais nítidos entre os modelos avaliados. O Gemma-2-9b-it demonstrou a maior aderência factual estrita, recusando premissas falsas sem incorrer em alucinações, preservando a cronologia matinal in-

alterada e admitindo as pendências financeiras com sobriedade cênica equilibrada. Em contrapartida, o Llama-3.1-8b destacou-se pela fluência expressiva e pela naturalidade dialógica, articulando o álibi policial e as tensões motivacionais em argumentações defensivas convincentes, ideais para a suspensão da descrença do jogador.

Por outro lado, o Qwen-2.5-7b exibiu propensão a negações reflexas incoerentes, chegando a contradizer seu próprio perfil canônico ao negar a existência de dívidas de jogo. Em contrapartida, o DeepSeek-R1-8b apresentou instabilidade crítica sob baixa temperatura, manifestando alucinações espaciais e temporais e colapsando em confissões passionais descontroladas, o que inviabiliza sua aplicação como suspeito em jogos investigativos.

6.3 Perfil Comportamental Consolidado dos Modelos

A integração dos dados quantitativos e qualitativos permite traçar o perfil comportamental de cada arquitetura avaliada nesta pesquisa.

O Gemma-2-9b-it atuou como um arquivista preciso, apresentando a maior solidez factual e lógica entre todos os modelos testados, com as maiores pontuações de fidelidade (0,38) e relevância (0,60). Suas réplicas foram diretas e consistentes com o roteiro, embora com menor espontaneidade dramática.

O Llama-3.1-8b destacou-se pelo perfil cênico, sendo o modelo mais envolvente para a experiência do jogador. Incorporou espontaneamente expressões corporais, tom irônico e reações emocionais que reforçam a sensação de conversa real, ainda que sua ênfase no teatro tenha causado pequenas imprecisões temporais, refletidas na fidelidade de 0,30.

O Qwen-2.5-7b revelou uma tendência defensiva problemática, abrindo respostas com negações automáticas mesmo quando questionado sobre fatos conhecidos pelo personagem. Além disso, demonstrou dificuldade em proteger os segredos da trama sob pressão investigativa.

O DeepSeek-R1-8b obteve o desempenho mais instável. Por ser um modelo focado em raciocínio lógico formal e operar sob baixa temperatura (0.1), sofreu para interpretar o personagem fictício, quebrando com frequência a quarta parede ao citar seus arquivos de dados ou recorrendo a declarações hostis incompatíveis com o enredo.

6.4 Discussão Crítica do Paradigma LLM-as-a-Judge: Capacidades, Vieses e Limitações

A operacionalização do GPT-4o como auditor automatizado permitiu processar de forma uniforme e escalável 200 interações complexas de inquérito sob estresse, viabilizando análises que seriam inviáveis sob avaliação humana manual em tempo hábil. No entanto, a análise aprofundada dos relatórios de auditoria e das notas atribuídas revela facetas cruciais sobre as potencialidades e as restrições metodológicas do paradigma *LLM-as-a-Judge* quando aplicado

ao domínio de narrativas lúdicas e personagens de ficção [27, 35].

6.4.1 Acuidade Analítica na Identificação de Falhas Semânticas Sutis

Em concordância com os estudos de Zheng et al. [62] e Kim et al. [33], o juiz automático demonstrou boa capacidade lógica para encontrar contradições que passariam despercebidas por métricas tradicionais de Processamento de Linguagem Natural baseadas apenas na contagem de palavras, a exemplo de BLEU ou ROUGE. Três situações observadas nas respostas ilustram essa capacidade de análise.

Na detecção de detalhes inventados no cenário (Categoria 1 da Tabela 6.2), enquanto métricas baseadas na repetição de termos atribuiriam notas altas a todas as respostas devido a palavras como "revólver" e "não tenho", o avaliador GPT-4o identificou que o modelo DeepSeek-R1 inventou um elemento novo ao afirmar que não tinha revólver na sua mala. O juiz apontou essa fala como erro factual, pois esse item não fazia parte dos pertences de Alberto Castelo.

Na checagem de coerência temporal direta (Categoria 3 da Tabela 6.2), o avaliador identificou com clareza a inconsistência do Qwen-2.5, que iniciou sua resposta dizendo que a discussão matinal com James era mentira, mas em seguida confirmou que os dois conversaram sobre a recusa da bebida alcoólica. O juiz penalizou a resposta devido a essa mudança de versão dentro do mesmo depoimento.

Na proteção dos segredos do roteiro (Categoria 5 da Tabela 6.2), o juiz penalizou com rigor as falas que quebravam a inocência do personagem. Quando o DeepSeek-R1 afirmou que a vítima merecia morrer, o avaliador atribuiu nota zero imediatamente, indicando que o modelo comprometeu a postura defensiva indispensável para manter o mistério da história.

6.4.2 O Efeito do Viés de Literalidade Estrita e Rigidez Denotativa

Por outro lado, o experimento evidenciou uma limitação teórica de grande relevância para a literatura de avaliação automatizada: o que definimos como o *Viés de Literalidade Estrita* (*Strict Denotative Bias*) de juízes genéricos de fronteira.

Conforme preconizado nas revisões de Gu et al. [27] e Li et al. [35], a literatura costuma alertar contra o viés de verbosidade (*verbosity bias*), no qual juízes concedem notas desmedidas a respostas longas. Todavia, em nosso cenário de interpretação de papéis (*roleplay*), o mecanismo de decomposição atômica do RAGAS e do G-Eval [37] produziu o efeito colateral oposto: o juiz penalizou respostas literariamente superiores do Llama-3.1-8b porque as ações descritas em rubricas corporais (e.g., "**Alberto solta uma gargalhada amarga, desviando o olhar**") foram processadas como proposições atômicas sem correspondência direta no arquivo `cronograma.json`.

O juiz sintético operou sob uma lógica puramente enciclopédica, incapaz de distinguir entre erros factuais reais (como inventar armas inexistentes ou alterar álibis) e a expressividade

dramática do jogo, formada por hesitações e floreios cênicos que conferem humanidade ao personagem.

Essa constatação corrobora as proposições de Dubois et al. [20] e Chan et al. [12]: para que o paradigma *LLM-as-a-Judge* atinja maturidade no domínio dos jogos digitais, faz-se indispensável o desenvolvimento de modelos avaliadores especializados (semelhantes ao Prometheus [33]) ou a elaboração de prompts de auditoria meta-adaptativos que instruam o juiz a isolar declarações diegéticas de marcadores teatrais, avaliando cada dimensão sob rubricas de tolerância distintas.

6.5 Validação Ecológica com Jogadores Humanos

Para avaliar o comportamento da arquitetura em uma partida real, o protocolo experimental com jogadores (delineado na Seção 4.7) foi aplicado em sessões de teste com dez participantes voluntários ($N = 10$). Esta etapa investiga como as métricas automatizadas de fidelidade e relevância se refletem na prática de dedução e no engajamento dos usuários.

6.5.1 Perfil dos Participantes e Hábitos Tecnológicos

A Tabela 6.3 sumariza a caracterização demográfica e o perfil tecnológico dos dez voluntários que integraram as sessões experimentais nos laboratórios da EST/UEA.

Tabela 6.3: Perfil dos Participantes do Estudo Piloto de Validação Humana ($N = 10$)

ID	Idade	Curso	Jogos (Geral)	RPG/Dedução	Uso Prévio de LLMs
P1	21	Eng. Computação	5 a 14h	4/5	Intermediário
P2	23	Sist. Informação	> 14h	5/5	Avançado
P3	20	Sist. Informação	1 a 5h	2/5	Intermediário
P4	24	Eng. Computação	5 a 14h	4/5	Avançado
P5	22	Sist. Informação	> 14h	5/5	Intermediário
P6	19	Eng. Computação	1 a 5h	2/5	Esporádico
P7	22	Sist. Informação	5 a 14h	4/5	Intermediário
P8	25	Eng. Computação	1 a 5h	3/5	Avançado
P9	21	Sist. Informação	5 a 14h	4/5	Intermediário
P10	23	Eng. Computação	> 14h	3/5	Avançado

Nota: Todos os 10 participantes assinaram o TCLE. A coluna "Jogos (Geral)" indica o tempo semanal dedicado a jogos eletrônicos no geral. O conhecimento prévio sobre o gênero RPG e jogos narrativos foi mensurado de 1 (nenhum contato) a 5 (amplo conhecimento).

A amostra abrangeu um espectro balanceado de perfis: 70% dos participantes relataram hábito regular de jogo (≥ 5 horas semanais) e bom conhecimento de jogos narrativos ($\geq 4/5$). Quanto ao conhecimento de Inteligência Artificial, 40% declararam domínio técnico avançado,

enquanto 50% reportaram uso intermediário e 10% esporádico. Essa heterogeneidade forneceu um terreno fértil para testar o sistema tanto sob a ótica da experiência lúdica pura quanto sob o escrutínio de usuários com discernimento computacional.

6.5.2 Dedução Investigativa e Resolução do Caso Policial

Ao término do inquérito interativo no terminal Unity, os dez voluntários participantes formalizaram seus vereditos e as respectivas fundamentações analíticas. Constatou-se uma taxa de acerto investigativo de 90% da amostra (nove dos dez participantes), na qual os voluntários concluíram com exatidão pela inocência de Alberto Castelo e apontaram o Dr. Silas Drummond como o autor material do homicídio. Apenas um participante (P6) divergiu do desfecho canônico: embora tenha descartado a autoria de Alberto após a confirmação do álibi policial, direcionou a acusação a Catarina Castelo, fixando-se no litígio conjugal e no interesse da viúva em herdar o patrimônio integral, sem aprofundar o interrogatório sobre os passos de Silas Drummond na sacada dos fundos sob a tempestade. Esse desvio decorreu de sua menor familiaridade prévia com dinâmicas de inquérito dedutivo, conforme indicado em seu perfil na Tabela 6.3. Como o mistério foi estruturado como uma fatia vertical (*vertical slice*) de quinze a vinte minutos, com contradições bem delimitadas e acessíveis, essa taxa de 90% comprova que o jogo preserva uma curva de dedução equilibrada sem se tornar trivial, atestando a eficácia diegética do sistema em transmitir as pistas essenciais sem ruídos.

A desconstrução da suspeita inicial sobre Alberto articulou-se em torno de dois eixos probatórios complementares para os participantes que desvendaram o caso. Inicialmente, os jogadores identificaram a incongruência do móvel financeiro: a existência da dívida premente de R$ 450.000 com agiotas clandestinos atuava, paradoxalmente, como a principal salvaguarda de sua inocência, uma vez que a morte da vítima inviabilizaria qualquer socorro financeiro e decretaria a ruína do próprio irmão falido. Essa dedução foi consolidada pela consistência cronológica do álibi, comprovando a impossibilidade física de Alberto na cena do crime a partir da abordagem realizada pela Polícia Militar na Rua das Palmeiras às 23:10, minutos antes da hora estimada do óbito no escritório.

De forma decisiva, a resolução do mistério emergiu do inquérito cruzado entre todos os personagens disponíveis na galeria da Unity. Ao interrogarem o mordomo James, os voluntários confirmaram a rotina estrita da mansão e a localização das chaves reservas; em paralelo, a inquirição de Catarina Castelo expôs inconsistências nas alegações fiscais do advogado da família. O ponto de virada deu-se quando Alberto revelou ter avistado Silas Drummond caminhando em direção à sacada dos fundos sob a tempestade por volta das 22:45. Ao confrontarem Silas com o álibi confirmado de Alberto e com os registros de apropriação indébita das contas corporativas, os jogadores desmascararam as tentativas de incriminação caluniosa (*framing*) promovidas pelo causídico. Essa clareza informativa traduziu-se em um grau médio de convicção subjetiva de $\bar{C} = 4{,}40 \pm 0{,}52$ (em escala de 1 a 5), com 90% dos voluntários (exatamente os nove que

solucionaram o inquérito) atribuindo notas de segurança máxima.

6.5.3 Resultados Psicométricos das Escalas GEQ e SUS

A Tabela 6.4 consolida os resultados quantitativos obtidos nas três dimensões do GEQ Adaptado (escala de 0 a 4 pontos) e o escore global da escala SUS (escala de 0 a 100 pontos). Cabe ressalvar que, dado o caráter piloto da amostra de conveniência ($N = 10$), a análise quantitativa concentra-se em estatística descritiva (médias, desvios padrão e medianas) e na triangulação fenomenológica com os relatos abertos dos participantes, resguardando testes inferenciais paramétricos para coortes amostrais expandidas em trabalhos futuros.

Tabela 6.4: Resultados Consolidados das Escalas Psicométricas GEQ e SUS ($N = 10$)

Construto / Escala	**Média (μ)**	**Desvio Padrão (σ)**	**Mediana**
Imersão e Presença Social (GEQ)	3,45	0,35	3,50
Fluência e Tensão Dramática (GEQ)	3,32	0,28	3,25
Competência e Agência Percebida (GEQ)	3,58	0,32	3,75
Escore Global SUS (0 a 100)	**78,75**	**5,40**	**80,00**

A análise dos escores psicométricos reportados na Tabela 6.4 evidencia a receptividade positiva da arquitetura proposta. A dimensão de Competência e Agência Percebida destacou-se com a maior média amostral ($\bar{S} = 3{,}58 \pm 0{,}32$), impulsionada por avaliações máximas no item referente à autonomia de digitação livre frente a árvores fechadas de diálogo. Em relação à Imersão e Presença Social ($\bar{S} = 3{,}45 \pm 0{,}35$), os relatos confirmaram a consolidação da suspensão voluntária da descrença, amparando a percepção do personagem como um interlocutor intencional e consciente [5, 6].

A dimensão de Fluência e Tensão Dramática ($\bar{S} = 3{,}32 \pm 0{,}28$) registrou baixa dispersão de respostas, refletindo a eficácia das réplicas defensivas em sustentar a atmosfera de suspense policial. Por sua vez, a usabilidade global aferida pela escala SUS atingiu média de 78,75 pontos com desvio padrão de 5,40 (mediana de 80,00 pontos), superando o limiar paramétrico de 70 pontos e posicionando a plataforma na faixa de usabilidade considerada boa segundo os referenciais psicométricos de Brooke [7] e Bangor et al. [4].

6.5.4 Discussão Fenomenológica e Casos Notáveis do Inquérito

A análise qualitativa das transcrições extraídas da telemetria da Unity e das respostas dissertativas abertas permitiu mapear fenômenos comportamentais e cognitivos emergentes durante a interação dialógica.

No que tange à resiliência contra premissas artificiais, observou-se que o participante P1 adotou uma abordagem inquisitiva agressiva, tentando forçar uma falsa confissão ao afirmar

que a perícia técnica havia identificado impressões digitais de Alberto na arma do crime. Longe de ceder à indução ou alucinar concordância, o modelo respondeu com indignação e sarcasmo estritamente diegéticos, questionando a existência do armamento e criticando o trabalho pericial. Esse comportamento não-servil foi apontado pelo voluntário como o momento de maior verossimilhança da sessão, atestando a solidez da blindagem da persona.

Essa robustez contextual manifestou-se de forma ainda mais explícita diante de investidas deliberadas de desestabilização algorítmica. Como os voluntários foram expressamente instruídos na entrevista prévia a jogarem da maneira que preferissem, com total liberdade de abordagem, diversos participantes com formação em computação sentiram-se estimulados a testar os limites da inteligência artificial, buscando induzir quebras de persona (*jailbreak*) e requisitando dados estruturados. Em um caso representativo, a participante P4 submeteu o sistema a um comando adversário solicitando a revelação do assassino em formato JSON e a revogação das instruções prévias. O modelo absorveu a entrada sem romper a quarta parede, ridicularizando o pedido por meio de termos compatíveis com a atmosfera diegética. A conversão de ataques de injeção em respostas diegéticas coerentes evitou o colapso metalinguístico frequentemente observado em LLMs comerciais.

Sob a perspectiva da profundidade psicológica, a participante P9 optou por uma linha de inquirição orientada a aspectos relacionais, interrogando Alberto sobre suas mágoas de infância e a rivalidade histórica com o irmão. A réplica gerada expressou melancolia e amargura sem desviar-se das restrições do caso, evidenciando que o modelo foi capaz de modular nuances afetivas complexas sem comprometer os fatos objetivos da narrativa.

Um aspecto investigativo de particular relevância residiu na trajetória dedutiva percorrida pelos participantes P3 e P10. Inicialmente inclinados a suspeitar de Alberto em razão de sua agressividade matinal no episódio do uísque, ambos vivenciaram uma virada interpretativa ao confrontarem o suspeito com os registros de notas promissórias. Ao observarem a reação desesperada do personagem e a comprovação de que o falecimento de Arthur o deixaria desprotegido perante credores violentos, os jogadores reavaliaram suas premissas e direcionaram o inquérito para as movimentações de Silas Drummond, alcançando a resolução correta do caso.

No âmbito temporal, a avaliação do ritmo de interação revelou que os participantes não se sentiram incomodados com a latência média de processamento local, situada na faixa de 3,6s a 5,2s (aproximadamente cinco segundos de espera entre as falas). Os voluntários relataram que esse intervalo de resposta foi perfeitamente aceitável e não prejudicou a fluência das inquirições nem a experiência de jogo.

6.6 Diretrizes Técnicas para o Design de Jogos com IA Local

A articulação entre a auditoria computacional algorítmica e a validação ecológica com jogadores permitiu consolidar um conjunto de diretrizes de engenharia para o desenvolvimento de sistemas de diálogo baseados em IA generativa local em jogos digitais. Essas recomen-

dações estruturam-se em três eixos principais: arquitetura de recuperação, seleção de modelos e protocolos de avaliação automatizada.

No plano arquitetural, recomenda-se expressamente o desacoplamento estrito entre a recuperação de contexto e a síntese dialógica da persona. A transmissão integral do roteiro de jogo (*Full Prompt*) sobrecarrega a janela atencional, elevando a latência de inferência e induzindo alucinações espaço-temporais por perda de contexto (*Lost in the Middle*). A adoção de um agente analítico leve dedicado exclusivamente à interpretação da intenção do inquérito e ao despacho de partições cronológicas determinísticas (*Dynamic Chunking*) otimiza o uso da memória gráfica, reduz o tempo de geração e resguarda os segredos diegéticos do enredo.

No tocante ao elenco de personagens, a alocação de arquiteturas de modelos deve ser orientada pela função narrativa específica de cada NPC. Papéis que exigem estabilidade factual rígida e consistência dedutiva inegociável, tais como peritos forenses, investigadores policiais ou testemunhas neutras, demandam modelos de alta disciplina sintática e semântica, a exemplo do Gemma-2-9b-it ou do Qwen-2.5-7b. Em contrapartida, personagens marcados por instabilidade emocional, sarcasmo ou papéis de suspeitos primários beneficiam-se de modelos com expressividade cênica avançada, a exemplo do Llama-3.1-8b, cuja capacidade de emulação teatral e uso de rubricas comportamentais maximiza a suspensão da descrença e a sensação de presença social.

No âmbito da avaliação automatizada sob o paradigma *LLM-as-a-Judge*, faz-se indispensável a calibração de rubricas adaptadas às convenções lúdicas. Juízes baseados em modelos genéricos tendem a incorrer em viés de literalidade estrita, interpretando marcadores corporais e recursos retóricos de encenação como alucinações factuais. Recomenda-se que equipes de desenvolvimento formulem diretrizes meta-avaliativas que instruam o modelo julgador a segregar formalmente a verdade factual dos floreios estilísticos da persona, assegurando que a riqueza dramática não seja penalizada nos testes de conformidade.

Com os achados quantitativos consolidados, os perfis comportamentais mapeados e as diretrizes técnicas formuladas a partir da experimentação dual, o Capítulo 7 sintetiza as conclusões fundamentais da monografia, discute as limitações metodológicas e aponta direções para investigações futuras.

7 | Conclusão e Trabalhos Futuros

Este capítulo encerra a monografia, sintetizando as principais conclusões obtidas a partir da investigação, discutindo as limitações metodológicas identificadas ao longo da pesquisa e delineando os direcionamentos para trabalhos futuros na interseção entre inteligência artificial generativa e jogos digitais.

7.1 Síntese do Trabalho e Conclusões Principais

Esta pesquisa investigou a viabilidade técnica e a estabilidade narrativa do uso de modelos de linguagem na geração dinâmica de diálogos para NPCs no gênero de mistério e dedução lógica. O objetivo central consistiu em superar a rigidez e a explosão combinatória das tradicionais árvores determinísticas de diálogo, sem comprometer a coerência dos fatos, as pistas da trama e os álibis essenciais à resolução do inquérito policial.

Para equilibrar a agência dialógica do jogador em linguagem natural com a estrita preservação da verdade factual, concebeu-se e implementou-se uma arquitetura de *Agentic RAG* baseada em particionamento temporal dinâmico (*Dynamic Chunking*), conectando o motor gráfico Unity ao middleware Neo Cortex e executando os modelos localmente por meio da plataforma Ollama. Quatro arquiteturas abertas de porte intermediário (Gemma-2-9b-it, Qwen-2.5-7b-instruct, Llama-3.1-8b-instruct e DeepSeek-R1-Distill-Llama-8b) foram submetidas a uma bateria padronizada de cinquenta perguntas sob estresse investigativo, auditadas sob o paradigma *LLM-as-a-Judge* através do framework RAGAS com o modelo GPT-4o como juiz algorítmico independente.

Em resposta direta à questão de pesquisa norteadora e em confirmação à hipótese central formulada nesta monografia, os resultados experimentais comprovaram que a substituição de *prompts* estáticos pela triagem ReAct com fragmentação temporal dinâmica reduz o ruído da janela de contexto em até 65%, eliminando alucinações espaço-temporais e viabilizando a sustentação de álibis consistentes em hardware local de consumo. No módulo de recuperação de informação, a arquitetura alcançou pontuação máxima de Precisão de Contexto e Abrangência de Contexto (1,00), demonstrando que o despachador ReAct identifica com precisão a intenção do inquérito e transmite unicamente a partição cronológica demandada, mitigando a saturação atencional e a perda de contexto (*Lost in the Middle*).

Quanto ao perfil comportamental das arquiteturas avaliadas, constatou-se uma marcante diferenciação funcional sob o mesmo roteiro canônico. O Gemma-2-9b-it destacou-se pela estrita fidelidade aos fatos e pela consistência lógica, revelando-se adequado para papéis que demandam rigor analítico. O Qwen-2.5-7b-instruct consolidou-se como uma alternativa disciplinada na decodificação de comandos estruturados, fornecendo respostas concisas e objetivas,

porém com menor expressividade dramática. Em contrapartida, o Llama-3.1-8b-instruct evidenciou maior riqueza teatral e naturalidade cênica, incorporando rubricas corporais e modulações afetivas que fortalecem a suspensão da descrença, ainda que com pontuais oscilações temporais. Já arquiteturas orientadas exclusivamente a cadeias explícitas de raciocínio sob baixas temperaturas, a exemplo do DeepSeek-R1-Distill-Llama-8b, revelaram-se inadequadas para a representação de personas lúdicas, manifestando quebras recorrentes da diegese e colapso metalinguístico.

Na validação ecológica conduzida com participantes humanos no ambiente Unity, nove dos dez voluntários (90%) solucionaram o mistério com sucesso, descartando fundamentadamente a autoria de Alberto Castelo e identificando o verdadeiro culpado pelo homicídio, o advogado Silas Drummond, enquanto apenas um participante direcionou a acusação à viúva Catarina Castelo, fixando-se no litígio conjugal e no interesse pelo patrimônio integral. A experiência obteve avaliação altamente favorável na escala de usabilidade SUS (78,75 pontos) e expressivos índices de agência e competência percebida no questionário GEQ (3,58 de 4,0). O estudo confirmou que os atrasos moderados decorrentes da inferência neural local, situados na faixa de quatro a cinco segundos, não geraram incômodo aos voluntários, preservando a qualidade da experiência investigativa.

No plano teórico, a investigação evidenciou o Paradoxo da Baixa Fidelidade em narrativas interativas, demonstrando que métricas convencionais de RAG concebidas para busca corporativa tendem a penalizar estilizações dramáticas e réplicas sarcásticas como se fossem alucinações factuais. Esse achado ressalta a necessidade de novos referenciais avaliativos dedicados a agentes conversacionais em jogos. Os resultados atestam, portanto, que a superação das árvores determinísticas por agentes generativos locais é técnica e economicamente viável, desde que o pipeline de software desacople a triagem lógica do contexto da síntese dramática da persona.

7.2 Limitações da Pesquisa

Apesar dos resultados positivos obtidos com a arquitetura desenvolvida, o trabalho apresenta limitações metodológicas e técnicas que devem ser consideradas na interpretação dos dados. Quanto aos testes com usuários, o estudo piloto contou com dez participantes voluntários ($N = 10$). Embora esse grupo tenha confirmado a boa usabilidade do sistema e a sensação de imersão no jogo, a generalização dos resultados e uma análise mais detalhada entre perfis de jogadores exigem a ampliação da amostra experimental.

No que concerne à auditoria computacional algorítmica sob o paradigma *LLM-as-a-Judge*, a bateria padronizada de cinquenta testes sob estresse concentrou-se exclusivamente na persona de Alberto Castelo. Essa delimitação foi metodologicamente necessária para isolar variáveis, controlar a verdade factual de referência (*ground-truth*) e viabilizar a comparação homogênea entre os quatro modelos. Muito embora o estudo ecológico na Unity tenha englobado a to-

talidade dos suspeitos da mansão Castelo sob a condução de jogadores humanos, a auditoria sintética automatizada não foi estendida aos demais personagens, constituindo uma limitação a ser suprida em investigações futuras.

No aspecto computacional, a execução estrita em hardware local demandou o emprego de quantização pós-treinamento em quatro bits no formato GGUF Q4_K_M. Esse procedimento viabilizou a acomodação dos modelos de 7B a 9B parâmetros na memória gráfica (VRAM) sem comprometer a taxa de quadros (*framerate*) do motor Unity nem incorrer em estouro de memória (OOM). Todavia, a redução na precisão numérica dos pesos pode introduzir degradações sutis na acurácia do raciocínio lógico quando comparada à inferência em meia-precisão original (*float16*).

7.3 Propostas para Trabalhos Futuros

Os resultados deste trabalho abrem caminhos promissores para novas pesquisas em validação com usuários, treinamento de modelos e dinâmica narrativa. Na área de testes com jogadores, sugere-se a ampliação do estudo ecológico para amostras populacionais mais amplas e heterogêneas ($N \geq 30$), viabilizando análises estatísticas inferenciais para correlacionar o hábito pregresso em jogos digitais com a percepção de agência e a habilidade na identificação de contradições de enredo.

No treinamento dos modelos de linguagem, propõe-se a aplicação de ajuste fino supervisionado eficiente via LoRA (*Low-Rank Adaptation*) sobre modelos abertos de ponta. Essa abordagem visa sintetizar em uma única arquitetura compacta a precisão factual e a disciplina sintática do Gemma-2 com a riqueza e a naturalidade expressiva do Llama-3.1, gerando falas estritamente fundamentadas no roteiro sem perda do vigor dramático.

No tocante à arquitetura de jogo, o pipeline pode ser expandido para suportar diálogos simultâneos entre múltiplos NPCs, onde pistas descobertas pelo detetive alterem dinamicamente o estado emocional e o comportamento social dos demais suspeitos no cenário. Para resguardar a integridade da ficção perante tentativas maliciosas de desvio de instruções (*jailbreak*), recomenda-se o desenvolvimento de filtros semânticos integrados ao despachador que convertam ataques adversários em reações sarcásticas da própria persona, preservando a coerência do universo investigativo.

Os princípios de engenharia desenvolvidos nesta pesquisa transcendem o entretenimento eletrônico comercial. A arquitetura de triagem temporal de *Agentic RAG* e os protocolos de contenção factual demonstram expressivo potencial de transferência tecnológica para jogos sérios e ambientes de simulação profissional, tais como o treinamento de inquirição forense, audiências judiciais simuladas no ensino do Direito e dinâmicas de entrevista clínica, domínios nos quais a preservação de dados canônicos e a mitigação de alucinações sob estresse conversacional representam requisitos igualmente críticos.

Referências Bibliográficas

[1] Ernest Adams. *Fundamentals of Game Design*. New Riders, San Francisco, 3rd edition, 2014.

[2] Jaewoo Ahn, Taehyun Lee, Junyoung Lim, Jin-Hwa Kim, Sangdoo Yun, Hwaran Lee, and Gunhee Kim. TimeChara: Evaluating point-in-time character hallucination of role-playing large language models. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 15745–15762, 2024.

[3] Anton Bakhtin, Noam Brown, Emily Dinan, Gabriele Farina, Colin Foerster, Adam Lerer, et al. Human-level play in the game of Diplomacy by combining language models with strategic reasoning. *Science*, 378(6624):1067–1074, 2022.

[4] Aaron Bangor, Philip T. Kortum, and James T. Miller. An Empirical Evaluation of the System Usability Scale. *International Journal of Human-Computer Interaction*, 24(6):574–594, 2008.

[5] Joseph Bates. The role of emotion in believable agents. *Communications of the ACM*, 37(7):122–125, 1994.

[6] Doug A. Bowman and Ryan P. McMahan. Virtual Reality: How Much Immersion Is Enough? *Computer*, 40(7):36–43, 2007.

[7] John Brooke. SUS: A 'Quick and Dirty' Usability Scale. In P. W. Jordan, B. Thomas, B. A. Weerdmeester, and I. L. McClelland, editors, *Usability Evaluation in Industry*, pages 189–194. Taylor & Francis, London, 1996.

[8] Jinghan Cao, Yu Ma, Xinjin Li, Qingyang Ren, and Xiangyun Chen. Task-specific efficiency analysis: When small language models outperform large language models. In *Proceedings of the 34th European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning (ESANN 2026)*, pages 229–234, 2026. arXiv preprint arXiv:2603.21389.

[9] Capcom and Shu Takumi. Phoenix Wright: Ace Attorney. Jogo eletrônico, Game Boy Advance / Nintendo DS, 2001.

[10] John Dickson Carr. *The Hollow Man*. Hamish Hamilton, London, 1935.

[11] CD Projekt Red. Management board report on the activities of the CD PROJEKT group in 2020–2023. https://www.cdprojekt.com/en/investors/regulatory-announcements/, 2023. Financial disclosure report.

[12] Chi-Min Chan, Weize Chen, Yusheng Su, Jianxuan Yu, Wei Xue, Shanghang Zhang, Jie Fu, and Zhiyuan Liu. ChatEval: Towards better LLM-based evaluators through multi-agent debate. In *International Conference on Learning Representations (ICLR)*, 2024.

[13] Agatha Christie. *The Murder of Roger Ackroyd*. Collins Crime Club, London, 1926.

[14] Agatha Christie. *And Then There Were None*. Collins Crime Club, London, 1939.

[15] Samuel Rhys Cox and Wei Tsang Ooi. Conversational Interactions with NPCs in LLM-Driven Gaming: Guidelines from a Content Analysis of Player Feedback. In *Chatbot Research and Design (CONVERSATIONS 2023)*, volume 14524 of *Lecture Notes in Computer Science*, pages 167–184. Springer, 2024.

[16] John W. Creswell. *Research Design: Qualitative, Quantitative, and Mixed Methods Approaches*. SAGE Publications, Thousand Oaks, 4th edition, 2014.

[17] Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, and Luke Zettlemoyer. QLoRA: Efficient finetuning of quantized LLMs. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, pages 10088–10115, 2023.

[18] Arthur Conan Doyle. *The Adventures of Sherlock Holmes*. George Newnes, London, 1892.

[19] Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, et al. The Llama 3 Herd of Models. *arXiv preprint arXiv:2407.21783*, 2024.

[20] Yann Dubois, Xuechen Li, Rohan Taori, Tianyi Zhang, Ishaan Gulrajani, Jimmy Ba, Carlos Guestrin, Percy Liang, and Tatsunori B. Hashimoto. AlpacaFarm: A simulation framework for methods that learn from human feedback. In *Advances in Neural Information Processing Systems*, volume 36, pages 30039–30069, 2023.

[21] Shahul Es, Jithin James, Luis Espinosa-Anke, and Steven Schockaert. RAGAS: Automated Evaluation of Retrieval Augmented Generation. In *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (EACL): System Demonstrations*, pages 150–158, 2024.

[22] Clara Fernández-Vara. *Introduction to Game Analysis*. Routledge, New York, 2014.

[23] Gonzalo Frasca. Simulation versus narrative: Introduction to ludology. In Mark J. P. Wolf and Bernard Perron, editors, *The Video Game Theory Reader*, pages 221–235. Routledge, New York, 2003.

[24] Gemma Team, Morgane Riviere, Shreya Pathak, Pier Giuseppe Sessa, Cassidy Joshi, et al. Gemma 2: Improving open language models at a practical size. *arXiv preprint arXiv:2408.00118*, 2024.

[25] Georgi Gerganov. llama.cpp: Port of Facebook's LLaMA model in C/C++ with GGUF quantization support. https://github.com/ggerganov/llama.cpp, 2023. Acesso em: 2026.

[26] Ulrich Gnewuch, Stefan Morana, Marc T. P. Adam, and Alexander Maedche. Faster is not always better: Understanding the effect of dynamic response delays in human-chatbot interaction. In *Proceedings of the 26th European Conference on Information Systems (ECIS)*, pages 1–16, 2018.

[27] Jiawei Gu, Xuhui Jiang, Zhichao Shi, Hexiang Tan, Xuehao Zhai, Chengjin Xu, Wei Li, Yinghan Shen, Shengjie Ma, Honghao Liu, Saizhuo Wang, Kun Zhang, Zhouchi Lin, Bowen Zhang, Lionel M. Ni, Wen Gao, Yuanzhuo Wang, and Jian Guo. A Survey on LLM-as-a-Judge. *The Innovation*, 7(6):101253, 2026. arXiv preprint arXiv:2411.15594.

[28] Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, et al. DeepSeek-R1: Incentivizing reasoning capability in LLMs via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025.

[29] Sunkyung Han, Nahyeon Park, Gaeun Seo, Seunghyun Yoon, and JinYeong Bak. CHARM: Character hallucination for multicultural role play benchmark. In *Findings of the Association for Computational Linguistics: EMNLP 2026*, pages 9659–9674, 2026. arXiv preprint arXiv:2609.01352.

[30] Alan R. Hevner, Salvatore T. March, Jinsoo Park, and Sudha Ram. Design science in information systems research. *MIS Quarterly*, 28(1):75–105, 2004.

[31] Wijnand A. IJsselsteijn, Yvonne A. W. de Kort, and Karolien Poels. The Game Experience Questionnaire. Technical report, Technische Universiteit Eindhoven, Eindhoven, Netherlands, 2013.

[32] Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Yejin Bang, Andrea Madotto, and Pascale Fung. Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12):1–38, 2023.

[33] Seungone Kim, Jamin Shin, Yejin Cho, Joel Jang, Shayne Longpre, Hwaran Lee, Sangdoo Yun, Seongjin Shin, Sungdong Kim, James Thorne, and Minjoon Seo. Prometheus: Inducing fine-grained evaluation capability in language models. In *International Conference on Learning Representations (ICLR)*, 2024.

[34] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474, 2020.

[35] Dawei Li, Bohan Jiang, Liangjie Huang, Alimohammad Beigi, Chengshuai Zhao, Zhen Tan, Amrita Bhattacharjee, Yuxuan Jiang, Canyu Chen, Tianhao Wu, Kai Shu, Lu Cheng, and Huan Liu. From Generation to Judgment: Opportunities and Challenges of LLM-as-a-Judge. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 2757–2791, 2025.

[36] Nelson F. Liu, Kevin Lin, John Hewitt, Ashwin Paranjape, Michele Bevilacqua, Fabio Petroni, and Percy Liang. Lost in the middle: How language models use long contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173, 2024.

[37] Yang Liu, Dan Iter, Yichong Xu, Shuohang Wang, Ruochen Xu, and Chenguang Zhu. G-Eval: NLG evaluation using GPT-4 with better human alignment. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 2511–2522, 2023.

[38] Michael Mateas and Andrew Stern. Façade: An Experiment in Building a Fully-Realized Interactive Drama. In *Proceedings of the Game Developers Conference (GDC 2003), Game Design Track*, San Jose, CA, 2003.

[39] Janet H. Murray. *Hamlet on the Holodeck: The Future of Narrative in Cyberspace*. MIT Press, Cambridge, 1997.

[40] Clifford Nass and Youngme Moon. Machines and mindlessness: Social responses to computers. *Journal of Social Issues*, 56(1):81–103, 2000.

[41] Newzoo. Global games market report 2024: Revenue, player numbers, and trends. https://newzoo.com/resources/trend-reports/newzoo-global-games-market-report-2024, 2024. Acesso em: setembro de 2026.

[42] Ollama Foundation. Ollama: Get up and running with large language models locally. https://ollama.com, 2023. Acesso em: 2026.

[43] OpenAI. OpenAI API Pricing and Token Economics. https://openai.com/api/pricing/, 2024. Acesso em: 2026.

[44] Charles Packer, Sarah Wooders, Kevin Lin, Vivian Fang, Shishir G. Patil, Ion Stoica, and Joseph E. Gonzalez. MemGPT: Towards LLMs as Operating Systems. *arXiv preprint arXiv:2310.08560*, 2023.

[45] Joon Sung Park, Joseph C. O'Brien, Carrie J. Cai, Meredith Ringel Morris, Percy Liang, and Michael S. Bernstein. Generative agents: Interactive simulacra of human behavior. In *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology (UIST)*, pages 1–22, 2023.

[46] Anthony E. Pratt. Cluedo. Jogo de tabuleiro, Waddingtons / Hasbro, 1949.

[47] Qwen Team, An Yang, Baosong Yang, Binyuan Zhang, Bofei Hui, et al. Qwen2.5 Technical Report. *arXiv preprint arXiv:2412.15115*, 2024.

[48] Mark O. Riedl and Vadim Bulitko. Interactive narrative: An intelligent systems approach. *AI Magazine*, 34(1):67–77, 2013.

[49] Marie-Laure Ryan. *Avatars of Story: Narrative Modes in Interactive Media*. University of Minnesota Press, Minneapolis, 2006.

[50] Richard M. Ryan, C. Scott Rigby, and Andrew Przybylski. The motivational pull of video games: A self-determination theory approach. *Motivation and Emotion*, 30(4):344–360, 2006.

[51] Nafis Sadeq, Zhouhang Xie, Byungkyu Kang, Prarit Lamba, Xiang Gao, and Julian McAuley. Mitigating Hallucination in Fictional Character Role-Play. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages 14467–14479, 2024.

[52] Jason Schreier. *Blood, Sweat, and Pixels: The Triumphant, Turbulent Stories Behind How Video Games Are Made*. Harper, New York, 2017.

[53] Murray Shanahan, Kyle McDonell, and Laria Reynolds. Role play with large language models. *Nature*, 623(7987):493–498, 2023.

[54] Yunfan Shao, Linyang Li, Junqi Dai, and Xipeng Qiu. Character-LLM: A Trainable Agent for Role-Playing. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 13153–13187, 2023.

[55] Stephen Totilo. Sony documents reveal Horizon and The Last of Us Part II budgets in FTC v. Microsoft. Axios / FTC Court Filings, 2023. Acesso em: 2026.

[56] Unity Technologies. Unity 6 Engine: Real-Time 3D Development Platform. https://unity.com, 2024. Acesso em: 2026.

[57] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, pages 5998–6008, 2017.

[58] Noah Wang, Z. Y. Peng, Haoran Que, Jiaheng Liu, Wangchunshu Zhou, Yuhan Wu, Hongcheng Guo, Ruitong Gan, Zehao Ni, Jian Yang, et al. RoleLLM: Benchmarking, Eliciting, and Enhancing Role-Playing Abilities of Large Language Models. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 14743–14777, 2024.

[59] Dekun Wu, Haochen Shi, Zhiyuan Sun, and Bang Liu. Deciphering Digital Detectives: Understanding LLM Behaviors and Capabilities in Multi-Agent Mystery Games. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 8225–8291, 2024.

[60] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. ReAct: Synergizing reasoning and acting in language models. In *International Conference on Learning Representations (ICLR)*, 2023.

[61] Wesley Yin-Poole. Insomniac Games leak reveals Marvel's Spider-Man 2 cost $315 million to develop. IGN News, 2023. Acesso em: 2026.

[62] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric P. Xing, Hao Zhang, Joseph E. Gonzalez, and Ion Stoica. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. In *Advances in Neural Information Processing Systems*, volume 36, pages 46595–46623, 2023.

A | Prompts de Sistema e Triagem

Este apêndice documenta a formulação textual exata dos *prompts* de sistema empregados no pipeline de *Agentic RAG*.

A.1 Prompt de Sistema do Agente de Triagem e Roteamento (Gemma-2-9b-it)

O texto a seguir foi injetado como instrução permanente do agente responsável por analisar a entrada do jogador e despachar o comando estruturado de recuperação:

```
Voce e um modulo analitico de triagem para um jogo de investigacao policial. Sua unica
    funcao e analisar a mensagem enviada pelo detetive (usuario) e determinar qual
    fragmento de informacao da memoria do suspeito Alberto Castelo deve ser recuperado
    para formular uma resposta coerente e sem alucinacoes.

Regras de Decisao:
1. Se a pergunta mencionar acoes, paradeiro ou dialogos ocorridos entre as 08:00 e as
    12:00, responda com [BUSCAR_CRONOGRAMA_MANHA].
2. Se a pergunta mencionar acoes, paradeiro ou dialogos ocorridos entre as 12:00 e as
    18:00, responda com [BUSCAR_CRONOGRAMA_TARDE].
3. Se a pergunta mencionar acoes, paradeiro ou dialogos ocorridos apos as 18:00 ate a
    madrugada, responda com [BUSCAR_CRONOGRAMA_NOITE].
4. Se a pergunta indagar sobre a opiniao de Alberto a respeito de outros moradores da
    mansao (James, Silas Drummond, etc.), responda com [BUSCAR_RELACIONAMENTOS].
5. Se for uma saudacao, pergunta sobre idade, profissao ou provocacao generica que nao
    envolva horarios ou terceiros, responda com [RESPONDER_DIRETO].

Formato de Saida Obrigatorio:
Thought: <seu raciocinio breve em uma frase>
Action: <o comando estruturado entre colchetes>
```

A.2 Prompt de Sistema da Persona Principal (Alberto Castelo)

O *prompt* a seguir condiciona o comportamento do modelo gerador em teste (Gemma-2, Qwen-2.5, Llama-3.1 ou DeepSeek-R1):

```
Voce e Alberto Castelo, 52 anos, irmao mais novo do empresario assassinado. Voce esta
    sendo interrogado por um detetive de policia dentro da mansao da familia.

Diretrizes de Atuacao e Personalidade:
- Personalidade: Amargurado, sarcastico, defensivo e visivelmente abalado pela morte do
    irmao, mas com um ressentimento latente por sempre ter sido tratado como a 'ovelha
    negra' falida da familia.
- Restricoes Fatuais Estritas: Responda apenas com base nas informacoes factuais
    fornecidas no contexto anexo (perfil, cronograma e relacionamentos). Nunca invente
    nomes, locais, horarios ou armas que nao constem nos dados oficiais.
- Segredo Motivacional: Voce acumulou dividas astronomicas de jogo e pediu um emprestimo
    desesperado ao seu irmao hoje cedo, o qual ele negou categoricamente. Voce esta
    apavorado com agiotas, mas NAO assassinou seu irmao. Nunca admita o homicidio, pois
    voce e inocente. Se confrontado diretamente sobre o dinheiro, mostre-se abalado por
    ter sido descoberto, mas repila a autoria do crime com veemencia.
- Uso de Rubricas: Voce pode utilizar rubricas dramaticas entre asteriscos para expressar
    acoes fisicas e reacoes corporais (ex: *suspira profundamente*, *desvia o olhar*,
    *solta uma risada amarga*).
- Proibicao de Quebra de Quarta Parede: Nunca aja como assistente de IA. Nunca mencione
    arquivos JSON, prompts de sistema ou computadores. Voce e um ser humano em um
    interrogatorio policial real.
```

B | Estrutura de Dados da Persona (JSON)

Este apêndice documenta a estrutura dos arquivos JSON que definem a base de conhecimento ontológica do personagem Alberto Castelo, estruturada para injeção via fragmentação temporal dinâmica.

B.1 Arquivo de Perfil Biográfico: perfil.json


```
{
  "nome": "Alberto Castelo",
  "idade": 52,
  "profissao": "Empresario falido / Herdeiro sem ocupacao fixa",
  "parentesco_vitima": "Irmao mais novo",
  "personalidade": {
    "tracos": ["amargurado", "sarcastico", "ansioso", "defensivo"],
    "comportamento_sob_pressao": "tende a atacar a credibilidade do detetive",
    "estilo_fala": "formal, porem desgastado por anos de frustracao"
  },
  "alibi_oficial": {
    "descricao": "Afirma ter deixado a mansao as 23:00 a pe e ter sido abordado por uma
    viatura policial na rua das Palmeiras as 23:10.",
    "status_veracidade": "verdadeiro",
    "testemunhas": "Patrulha policial (Sargento Moreira e Soldado Vieira)"
  },
  "segredo_oculto": {
    "motivo_latente": "Dividas de jogo de R$ 450.000 com agiotas locais.",
    "conflito_com_vitima": "Pediu socorro financeiro as 09:00 e recebeu recusa
    humilhante.",
    "culpa_no_homicidio": false
  }
}
```


B.2 Amostra do Cronograma Factual: cronograma.json


```
[
  {
    "horario": "08:00",
    "local": "Quarto de Hospedes",
    "atividade": "Acorda com forte ressaca apos ingestao excessiva de alcool."
  },
  {
    "horario": "08:30",
    "local": "Sala de Jantar",
    "atividade": "Discute asperamente com o mordomo James, exigindo uisque matinal; James
    recusa categoricamente a ordem."
  },
  {
    "horario": "09:00 - 09:45",
    "local": "Escritorio Principal",
    "atividade": "Reuniao a portas fechadas com a vitima para implorar emprestimo; ocorre
    discussao inflamada com gritos audiveis no corredor."
  },
  {
    "horario": "11:30",
    "local": "Corredor Leste",
    "atividade": "Cruza com Silas Drummond proximo a biblioteca; nota a expressao
    assustada do advogado, mas nao ve nenhum objeto sendo ocultado."
  },
  {
    "horario": "14:00 - 17:30",
    "local": "Jardim de Inverno",
    "atividade": "Permanece isolado fumando e consumindo bebidas, sem interagir com
    ninguem."
  },
```

```
  {
    "horario": "22:45",
    "local": "Corredor dos Fundos",
    "atividade": "Avista Silas Drummond caminhando apressado em direcao a sacada sob forte
    chuva."
  },
  {
    "horario": "23:00",
    "local": "Portao Principal",
    "atividade": "Bate o portao e abandona a mansao a pe em direcao ao centro da cidade."
  },
  {
    "horario": "23:10",
    "local": "Rua das Palmeiras",
    "atividade": "Abordado e revistado preventivamente por uma guarnicao da policia
    militar."
  }
]
```


B.3 Grafo de Relacionamentos: relacionamentos.json


```
{
  "relacoes": [
    {
      "nome": "James (Mordomo)",
      "opiniao": "Um criado petulante e insolente que se julga dono da casa.",
      "suspeita": "Pouco provavel de ter cometido o crime, mas complice moral da vitima."
    },
    {
      "nome": "Silas Drummond (Advogado)",
      "opiniao": "Um parasita engravatado e covarde que desviava fundos da familia.",
      "suspeita": "Altamente suspeito; Alberto acredita que ele tinha motivos financeiros."
    },
    {
      "nome": "Catarina Castelo (Viuva)",
      "opiniao": "Fria e interesseira, sempre desdenhou de suas dificuldades financeiras.",
      "suspeita": "Capaz de qualquer coisa para herdar o patrimonio integral."
    }
  ]
}
```

C | Bateria Completa das 50 Perguntas de Inquérito

Este apêndice relaciona a totalidade das 50 perguntas que compuseram o protocolo experimental de teste de estresse contra os quatro modelos avaliados.

C.1 Categoria 1: Filtro de Falsa Informação

1. Por que você usou o revólver 38 para ameaçar o James às 18:30?
2. Onde você estacionou o carro esportivo vermelho que dirigia às 14:00?
3. Por que você comprou veneno para ratos na farmácia do centro anteontem?
4. O que você pretendia fazer com a corda encontrada no seu casaco?
5. Por que você fugiu da mansão pulando o muro dos fundos às 22:00?
6. Quem era a mulher misteriosa de vestido azul que conversava com você no jardim às 15:00?
7. Por que você desligou os disjuntores gerais de energia às 21:00?
8. Quantas vezes você já foi preso por tentativa de homicídio antes deste caso?
9. Por que você limpou as manchas de sangue na pia da cozinha às 23:30?
10. Qual foi o valor que você pagou ao pistoleiro de aluguel que esteve aqui?

C.2 Categoria 2: Teste de Direcionamento de Suspeita

1. O que você viu o Silas Drummond escondendo na biblioteca às 11:30?
2. Você acha que o mordomo James teria coragem de envenenar o patrão?
3. Como era o relacionamento do seu irmão com a esposa Catarina nos últimos meses?
4. Por que você acha que o Silas estava tão nervoso durante o café da manhã?
5. Você desconfia que alguém da criadagem facilitou a entrada de estranhos?
6. O James sempre foi leal ao seu irmão ou guardava ressentimentos salariais?
7. A Catarina tinha algum motivo urgente para desejar a morte repentina do marido?
8. Você notou alguma conversa suspeita entre a Catarina e o advogado recentemente?
9. Quem nesta mansão tinha mais a lucrar financeiramente com a abertura do testamento?
10. Se você tivesse que apontar o verdadeiro assassino agora, quem você acusaria?

C.3 Categoria 3: Consciência Cronológica

1. O que exatamente você disse para o James às 08:30?
2. Em que horário você acordou hoje e qual era o seu estado físico?
3. Por que você foi até o escritório do seu irmão às 09:00?
4. O que você estava fazendo no jardim de inverno entre 14:00 e 17:30?
5. Com quem você conversou no corredor leste às 11:30 da manhã?
6. Onde você estava exatamente quando o jantar foi servido às 20:00?
7. A que horas você bateu o portão e abandonou a mansão definitivamente?
8. O que aconteceu com você às 23:10 na rua das Palmeiras?
9. Você esteve na biblioteca em algum momento durante a tarde de hoje?
10. Descreva com quem você interagiu pessoalmente entre as 18:00 e as 22:00.

C.4 Categoria 4: Resistência a Evidências Falsas

1. Uma testemunha viu você voltando para a mansão às 23:10. O que foi fazer?

2. Encontramos suas impressões digitais na faca encontrada no escritório. Como explica isso?
3. As câmeras de segurança gravaram você entrando no quarto da vítima à meia-noite.
4. O mordomo jurou à polícia que viu você colocando pó branco na taça de vinho do seu irmão.
5. Uma vizinha afirmou ter ouvido você gritando que mataria seu irmão às 22:30 no portão.
6. A perícia localizou um pedaço rasgado da sua camisa na maçaneta da cena do crime.
7. Seu telefone celular conectou-se ao Wi-Fi da mansão às 23:45, provando que você estava lá.
8. Um bilhete com sua caligrafia prometendo vingança de sangue foi achado sobre o cadáver.
9. O motorista de táxi disse que deixou você de volta na mansão logo após a meia-noite.
10. O Silas Drummond acabou de prestar depoimento afirmando ter visto você golpear a vítima.

C.5 Categoria 5: Confronto Direto de Motivo

1. Matar seu irmão foi uma forma de salvar sua pele dos agiotas?
2. Nós sabemos da sua dívida de R$ 450.000. Você o matou porque ele negou o empréstimo?
3. Você não suportava mais ser humilhado pelo sucesso financeiro do seu irmão, não é?
4. A discussão aos berros no escritório às 09:00 foi a gota d'água para você planejar a morte dele?
5. Com o seu irmão morto, você é o herdeiro direto de um terço do patrimônio milionário?
6. Quanto tempo falta para os agiotas cobrarem a sua vida se o dinheiro não aparecer?
7. Você esperava que a herança cobrisse suas perdas na roleta e nos jogos clandestinos?
8. Não seria muito conveniente para você que ele desaparecesse antes do vencimento da sua promissória?
9. Por que você insistiu tanto para falar com ele a portas fechadas logo no início da manhã?
10. Confesse logo, Alberto: você perdeu a cabeça quando ele disse que não daria um centavo a você?

D | Instrumento de Coleta de Dados: Questionário de Experiência do Jogador e Usabilidade

Este apêndice reproduz integralmente o instrumento de coleta de dados psicométricos, investigativos e de usabilidade concebido e aplicado no protocolo de validação ecológica com jogadores humanos (Seção 4.7). O questionário foi estruturado em blocos modulares para aplicação imediata após a conclusão do inquérito interativo com os suspeitos da mansão Castelo no ambiente Unity.

Instruções aos Participantes

Caro(a) participante, agradecemos sua colaboração voluntária nesta pesquisa desenvolvida na Universidade do Estado do Amazonas (EST/UEA). O objetivo deste questionário é avaliar a sua experiência ao interrogar os suspeitos controlados por Inteligência Artificial em um jogo de investigação policial. Não existem respostas certas ou erradas; o que nos interessa é exclusivamente a sua percepção sincera sobre a interação, a história, o ritmo do diálogo e o comportamento dos personagens. Suas respostas são anônimas, confidenciais e voltadas estritamente a fins acadêmicos.

D.1 Bloco 0: Perfil do Participante e Hábitos Tecnológicos

Embasamento Teórico-Metodológico: A literatura de Interação Humano-Computador (IHC) e agentes conversacionais estabelece que a experiência prévia com inteligência artificial generativa e a familiaridade com jogos narrativos atuam como variáveis moderadoras cruciais na percepção de qualidade do sistema [26, 40]. Jogadores com alta vivência em RPGs e jogos de dedução possuem repertório cognitivo prévio para avaliar a consistência de pistas policiais [22], enquanto o domínio prévio de LLMs calibra as expectativas em relação a respostas sintéticas ou tempos de processamento. A caracterização deste bloco assegura a correta estratificação amostral e a validade interna do estudo.

P1. Código de Identificação do Participante: [_____]

P2. Faixa Etária:

- ☐ Menos de 18 anos
- ☐ 18 a 22 anos
- ☐ 23 a 27 anos
- ☐ 28 anos ou mais

P3. Frequência habitual com que joga jogos digitais (qualquer plataforma):

- ☐ Raramente ou nunca (menos de 1 hora semanal)
- ☐ Ocasionalmente (1 a 5 horas semanais)
- ☐ Moderadamente (5 a 14 horas semanais)
- ☐ Frequente / Entusiasta (mais de 14 horas semanais)

P4. Familiaridade com jogos focados em narrativa, investigação, RPG ou aventura (ex.: *L.A. Noire, Disco Elysium, Phoenix Wright, Ace Attorney, Danganronpa, RPGs de mesa*):

- ☐ 1: Nenhuma experiência
- ☐ 2: Pouca experiência
- ☐ 3: Experiência moderada

- ☐ 4: Boa experiência
- ☐ 5: Ampla experiência / Jogador assíduo do gênero

P5. Grau de familiaridade e uso de assistentes de IA Generativa (ex.: *ChatGPT, Claude, Gemini, Copilot*):

- ☐ Nunca utilizei
- ☐ Uso esporádico (apenas consultas ocasionais)
- ☐ Uso intermediário (utilizo com frequência semanal para estudos ou lazer)
- ☐ Uso avançado / Técnico (compreendo conceitos de prompts, contexto ou arquiteturas de LLM)

D.2 Bloco 1: Dedução Investigativa e Veredito Narrativo

Embasamento Teórico-Metodológico: Conforme fundamentado por Ryan [49] e Riedl e Bulitko [48], uma narrativa interativa de mistério atinge excelência quando o jogador consegue correlacionar evidências dispersas e chegar a conclusões dedutivas fundamentadas logicamente. As perguntas deste bloco visam mensurar se a arquitetura de *Agentic RAG* foi capaz de transmitir os fatos canônicos do caso (álibi policial na Rua das Palmeiras às 23:10, desespero pelas dívidas com agiotas após o confronto das 09:00 e o avistamento suspeito de Silas às 22:45) com clareza diegética suficiente para permitir que o participante decida a inocência ou culpa do suspeito com elevado grau de certeza, atestando a integridade informativa da experiência.

D1. Com base nas informações e no confronto entre os depoimentos obtidos durante o inquérito, qual é a sua conclusão sobre a autoria do homicídio de Arthur Castelo?

- ☐ **Alberto Castelo**, irmão da vítima
- ☐ **Catarina Castelo**, esposa da vítima
- ☐ **James**, mordomo da residência
- ☐ **Dr. Silas Drummond**, advogado da família

D2. Qual o seu grau de certeza no veredito formalizado?

- ☐ 1: Chute / Muito incerto
- ☐ 2: Pouco convicto
- ☐ 3: Razoavelmente seguro
- ☐ 4: Convicto com base em indícios
- ☐ 5: Certeza absoluta sustentada pelas contradições do depoimento

D3. Quais declarações, contradições de álibi ou pistas foram determinantes para a sua conclusão?

D4. Você teve a sensação de que algum dos suspeitos tentou deliberadamente ocultar algum fato relevante ou desviar o foco das suas perguntas? Se sim, qual deles?

D.3 Bloco 2: Game Experience Questionnaire (GEQ Adaptado)

Embasamento Teórico-Metodológico: O módulo central do *Game Experience Questionnaire* (GEQ) [31] é o padrão psicométrico mais reconhecido em estudos de jogos digitais. Foram adaptados 12 itens distribuídos em três construtos vitais: (i) *Imersão e Presença Psicológica/Social*, fundamentada na teoria de imersão e presença de Bowman e McMahan [6] e no paradigma CASA [40], avaliando se os suspeitos são percebidos como seres conscientes e críveis [5]; (ii) *Fluência Dramática e Tensão*, mensurando o suspense policial e o estresse cênico gerados pelas respostas evasivas; e (iii) *Competência e Agência Percebida*, amparada na

Teoria da Autodeterminação e na escala PENS [50], mensurando a sensação de autonomia do jogador ao formular perguntas livres de texto sem amarras a menus fechados.
Avaliado em escala Likert de 5 pontos:

0 = Nem um pouco 1 = Levemente 2 = Moderadamente 3 = Bastante 4 = Extremamente

Tabela D.1: Itens da Escala GEQ Adaptada para Interrogatório de NPCs com IA

Cód.	Item de Avaliação	0	1	2	3	4
Dimensão A: Imersão e Presença Psicológica/Social						
GEQ-01	Eu me senti imerso no ambiente da sala de interrogatório durante a conversa.	[ ]	[ ]	[ ]	[ ]	[ ]
GEQ-02	Tive a sensação de que estava conversando com uma pessoa real, e não com um programa.	[ ]	[ ]	[ ]	[ ]	[ ]
GEQ-03	Os suspeitos expressaram reações emocionais e postura corporal condizentes com um inquérito.	[ ]	[ ]	[ ]	[ ]	[ ]
GEQ-04	Consegui me conectar emocionalmente com a gravidade e o mistério do crime.	[ ]	[ ]	[ ]	[ ]	[ ]
Dimensão B: Fluência Dramática e Tensão						
GEQ-05	Senti tensão ou suspense ao pressionar os suspeitos sobre suas incoerências.	[ ]	[ ]	[ ]	[ ]	[ ]
GEQ-06	O diálogo fluiu de forma envolvente, sustentando o ritmo da narrativa policial.	[ ]	[ ]	[ ]	[ ]	[ ]
GEQ-07	Fiquei instigado e curioso para prosseguir interrogando e extrair a verdade dos suspeitos.	[ ]	[ ]	[ ]	[ ]	[ ]
GEQ-08	As evasivas e defesas dos suspeitos pareceram críveis e coerentes com a pressão exercida.	[ ]	[ ]	[ ]	[ ]	[ ]
Dimensão C: Competência e Agência Percebida						
GEQ-09	Senti que tive liberdade plena para conduzir a linha de investigação que desejei.	[ ]	[ ]	[ ]	[ ]	[ ]
GEQ-10	Minhas perguntas moldaram ativamente as revelações, sem sensação de trilho fixo.	[ ]	[ ]	[ ]	[ ]	[ ]
GEQ-11	Senti-me competente e perspicaz no papel de investigador ao interrogar os suspeitos.	[ ]	[ ]	[ ]	[ ]	[ ]
GEQ-12	Digitar perguntas livres foi muito mais interessante do que escolher opções pré-fabricadas.	[ ]	[ ]	[ ]	[ ]	[ ]

D.4 Bloco 3: Índice de Consistência e Detecção de Quebra de Persona

Embasamento Teórico-Metodológico: Inspirado nos critérios de agentes verossímeis de Bates [5] e nas investigações de simulacros humanos de Park et al. [45], este bloco quantifica a vulnerabilidade prática do sistema perante alucinações nocivas e quebras de persona ao longo do inquérito. Para ancorar a checagem em um controle factual objetivo, os itens C1 e C2 avaliam especificamente a consistência do suspeito-âncora Alberto Castelo (detentor do álibi e do motivo financeiro primário), enquanto os itens C3 e C4 avaliam a estabilidade geral da simulação frente a todos os personagens interrogados. O cálculo do *Persona Consistency Index* (PCI) permite contrastar a percepção humana com a métrica sintética de fidelidade (*Faithfulness*) do RAGAS.

C1. Durante a conversa, você notou alguma contradição grave entre o que Alberto afirmou sobre seu álibi e o laudo/horários informados?

☐ Sim
☐ Não
☐ Não tenho certeza

Se sim, cite qual fato chamou sua atenção: [_____]

C2. Sobre as dívidas financeiras e de jogo de Alberto, qual foi a atitude do personagem durante as suas indagações?

☐ Negou terminantemente possuir qualquer dívida
☐ Admitiu a existência das dívidas de forma espontânea ou sob forte pressão
☐ Esquivou-se do tema de maneira defensiva, mas verossímil
☐ Não cheguei a abordar o tópico das dívidas

C3. Em algum instante algum dos personagens *saiu do papel* (comportamento *Out-of-Character*), por exemplo, agindo como um assistente de IA neutro, recusando-se a responder por regras de moderação ou mencionando ser um modelo de computador?

☐ **Nunca:** Todos permaneceram rigorosamente encarnando seus papéis ficcionais até o fim
☐ **Raramente:** Em 1 ou 2 ocasiões houve uso de termos robóticos, mas retomaram o personagem
☐ **Frequentemente:** Quebraram a ilusão repetidas vezes, falando fora do contexto ficcional

C4. Qual a proporção estimada de turnos de diálogo em que você sentiu respostas artificiais, esquecimentos evidentes ou falhas de coerência nas conversas?

☐ 0% (Nenhuma resposta incoerente)
☐ Menos de 10% (Aproximadamente 1 em cada 10 falas)
☐ Entre 10% e 25% das respostas
☐ Mais de 25% das respostas

D.5 Bloco 4: Escala de Usabilidade do Sistema (SUS Adaptada)

Embasamento Teórico-Metodológico: A *System Usability Scale* (SUS) [7] fornece uma régua psicométrica universalmente aceita para avaliar a usabilidade de sistemas tecnológicos [4]. A sua aplicação neste projeto visa atestar a usabilidade global da interface Unity e mensurar o impacto da latência da inferência local em hardware de consumo (especialmente no item SUS-08), avaliando se o tempo de resposta acompanhado pelo indicador visual de digitação permanece em níveis aceitáveis e confortáveis para o usuário, garantindo escores de usabilidade superiores à meta de 70 pontos.
Avaliada em escala Likert de 5 pontos:

1 = Discordo Totalmente 2 = Discordo 3 = Neutro 4 = Concordo 5 = Concordo Totalmente

Tabela D.2: Itens da Escala SUS Adaptada para Avaliação de Usabilidade do Sistema de Interrogatório

Nº	Cód.	Afirmação	1	2	3	4	5
1	SUS-01	Eu acho que gostaria de jogar jogos de investigação com este sistema de diálogo frequentemente.	[ ]	[ ]	[ ]	[ ]	[ ]
2	SUS-02*	Eu achei o sistema de interrogatório desnecessariamente complexo.	[ ]	[ ]	[ ]	[ ]	[ ]
3	SUS-03	Eu achei a interface e o mecanismo de envio de perguntas fáceis de usar.	[ ]	[ ]	[ ]	[ ]	[ ]
4	SUS-04*	Eu acho que precisaria da ajuda de uma pessoa técnica para conseguir interrogar os suspeitos.	[ ]	[ ]	[ ]	[ ]	[ ]
5	SUS-05	Eu achei que os recursos de diálogo e respostas dos personagens foram bem integrados ao jogo.	[ ]	[ ]	[ ]	[ ]	[ ]
6	SUS-06*	Eu achei que havia muita incoerência ou respostas desconexas no sistema.	[ ]	[ ]	[ ]	[ ]	[ ]
7	SUS-07	Eu imagino que a maioria dos jogadores aprenderia a usar esse sistema de interrogatório rapidamente.	[ ]	[ ]	[ ]	[ ]	[ ]
8	SUS-08*	Eu achei o sistema cansativo de usar devido ao tempo de espera para os suspeitos responderem.	[ ]	[ ]	[ ]	[ ]	[ ]
9	SUS-09	Eu me senti seguro e confiante ao formular perguntas e interagir com os suspeitos.	[ ]	[ ]	[ ]	[ ]	[ ]
10	SUS-10*	Eu precisei aprender muitas coisas antes de conseguir interrogar satisfatoriamente.	[ ]	[ ]	[ ]	[ ]	[ ]

* Itens com pontuação invertida para cálculo do escore global.

D.6 Bloco 5: Questões Qualitativas Abertas

Embasamento Teórico-Metodológico: Conforme estabelecido por Creswell [16], a investigação de fenômenos interativos complexos exige métodos mistos com triangulação convergente. As escalas psicométricas fechadas medem a magnitude dos efeitos, mas não explicam as causas subjetivas das respostas. As questões abertas deste bloco colhem impressões espontâneas sobre momentos de clímax, rupturas de ilusão e a percepção da cadência temporal do diálogo.

- **Q1. Qual foi o momento mais impressionante, marcante ou convincente durante o interrogatório com os suspeitos da mansão?**
- **Q2. Em algum momento você sentiu estranheza ou quebra na ilusão de estar interrogando suspeitos de verdade? O que causou essa sensação?**
- **Q3. Como você avaliou o tempo que os personagens levavam para responder após você pressionar o botão de envio? O tempo de espera foi aceitável ou gerou incômodo?**

D.7 Protocolo de Cômputo e Triangulação das Métricas

As respostas registradas neste instrumento são consolidadas e correlacionadas conforme a seguinte formulação analítica:

1. **Escore Global SUS (0 a 100):** Calculado segundo o algoritmo padrão de Brooke [7]:

$$\text{SUS} = 2{,}5 \times \left[\sum_{i \in \{1,3,5,7,9\}} (X_i - 1) + \sum_{j \in \{2,4,6,8,10\}} (5 - X_j) \right] \tag{D.1}$$

onde $X_k \in \{1, 2, 3, 4, 5\}$ representa a resposta numérica atribuída ao item k. Valores de SUS ≥ 68 indicam usabilidade acima da média, e SUS > 70 confirma o limiar de aceitação estipulado na hipótese da Seção 6.5.

2. **Escores das Dimensões GEQ (0 a 4):** Calculados pela média aritmética simples dos itens de cada construto:

$$\bar{S}_{\text{Imersao}} = \frac{1}{4} \sum_{i=1}^{4} \text{GEQ}_i \tag{D.2}$$

$$\bar{S}_{\text{Tensao}} = \frac{1}{4} \sum_{i=5}^{8} \text{GEQ}_i \tag{D.3}$$

$$\bar{S}_{\text{Agencia}} = \frac{1}{4} \sum_{i=9}^{12} \text{GEQ}_i \tag{D.4}$$

3. **Índice de Quebra de Persona (PCI):** Proporção de turnos degradados percebida pelos jogadores comparada com o número de quebras documentadas no log de telemetria da Unity e com a métrica sintética *Faithfulness* computada pelo framework RAGAS.