Avaliação de Modelos de Linguagem de Grande Escala na Geração Dinâmica de Diálogos para NPCs em Jogos de Investigação

João Lucas Noronha de Castro
Orientador: Prof. Dr. Luis Cuevas Rodriguez

Universidade do Estado do Amazonas (UEA)
Curso de Sistemas de Informação

Junho de 2026

Sumário

1. Introdução
2. A Solução
3. O Jogo de Investigação
4. Arquitetura Proposta
5. Metodologia
6. Resultados e Análise
7. Conclusões
8. Cronograma de TCC 2
9. Referências

Introdução e Contextualização

- **Crescimento da Indústria:** Expansão do mercado de jogos digitais impulsiona a demanda por mundos virtuais mais ricos, imersivos e narrativamente complexos.
- **Narrativas de Alto Orçamento:** Ciclos de produção mais longos, equipes gigantescas e altos custos de desenvolvimento.
- **Inteligência Artificial Generativa:** Surge como alternativa para automatizar e escalar o design narrativo dinâmico de forma viável.

O Problema: Árvores de Diálogo Estáticas

- **Rigidez Estrutural:** Diálogos tradicionais são sustentados por árvores determinísticas e pré-escritas [Adams 2014].
- **Gargalo de Autoria:** Exige esforço manual exaustivo para criar todas as ramificações possíveis.

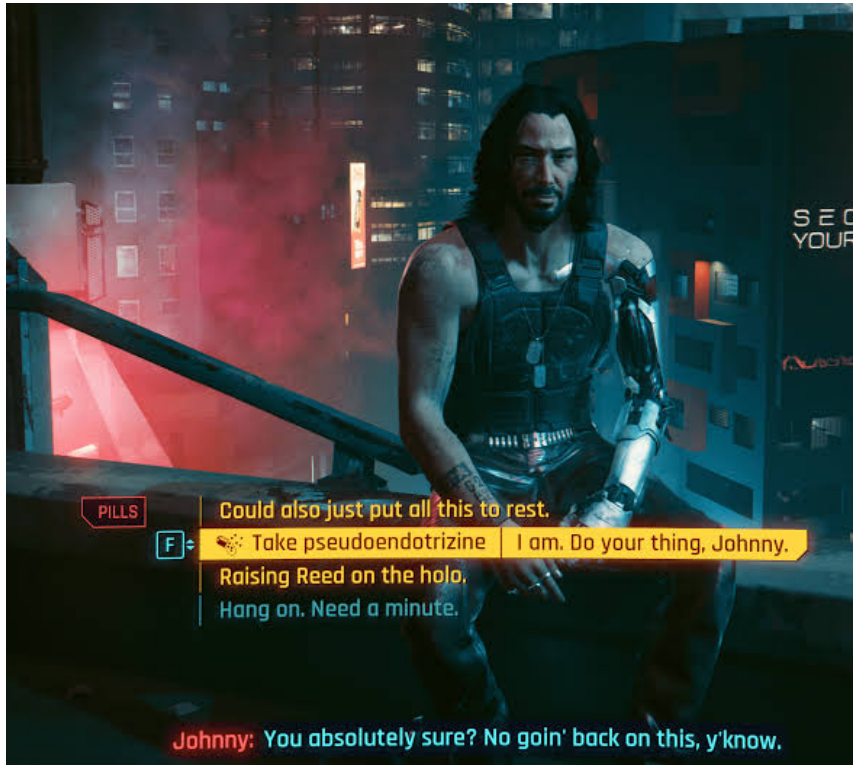


Figura 1: Exemplo de diálogo em jogos.

O Problema: Complexidade e Agência

- **Explosão Combinatória:** Rastrear múltiplos caminhos torna-se extremamente difícil e custoso para a equipe.
- **Limitação de Agência:** O jogador fica travado em opções pré-selecionadas de conversa, reduzindo a naturalidade do interrogatório.

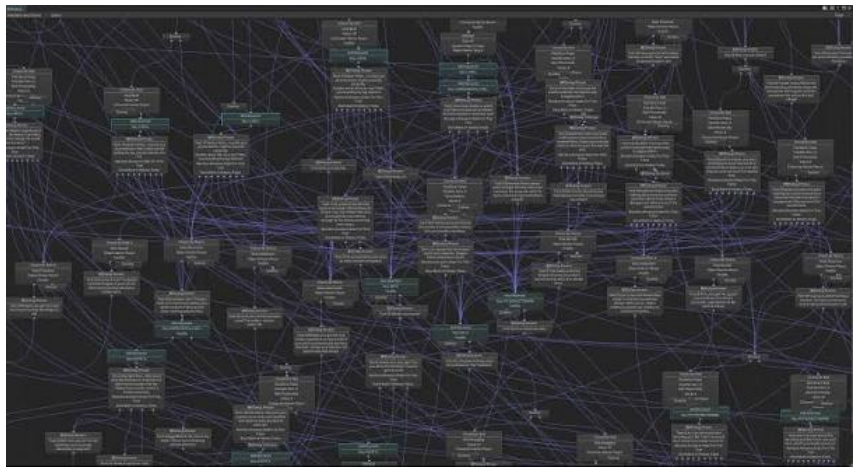


Figura 2: Exemplo de uma árvore de diálogo.

A Solução: Parametrização e LLMs

- **Transição de Paradigma:** Passagem da codificação literal de diálogos para a parametrização do contexto de personas [Shanahan et al. 2023].
- **Geração Dinâmica:** Utilização de Modelos de Linguagem (LLMs) executados localmente para interpretar e gerar respostas em tempo real.
- **Vulnerabilidades Técnicas da IA Generativa:**
  - **Alucinações:** Geração de informações incorretas (ex: inventar fatos ou confessar crimes indevidamente) [Ji et al. 2023].
  - **Degradação de Memória:** Perda de consistência espaço-temporal ao longo de conversas extensas, arruinando a mecânica do mistério [Murray 1997].

Mecânicas do Jogo de Investigação

- **Papel do Jogador:** O jogador assume a identidade de um **detetive** encarregado de desvendar crimes específicos por etapas.
- **Livre Inquérito:** A mecânica central baseia-se na formulação livre de perguntas por meio de entrada de texto direto.
- **Cruzamento de Depoimentos:** O jogador deve interrogar múltiplos suspeitos (NPCs autônomos), cruzar seus álibis e relatos temporais.
- **Dedução Lógica:** A progressão de fases e a solução do mistério dependem da identificação de inconsistências factuais e do culpado real.

Arquitetura Proposta: Agentic RAG e Chunking

- **Infraestrutura:** Implementação no motor gráfico **Unity** conectada a LLMs locais via **Neo Cortex** e **Ollama**.
- **Representação de Persona (JSON):**
  - **Perfil:** Identidade, segredo e álibi do suspeito.
  - **Cronograma:** Agenda horária detalhada de suas ações (08:00 - 01:00).
  - **Relacionamentos:** Visão subjetiva sobre outros personagens.

Justificativa da Arquitetura Híbrida

Em abordagens de *Full Prompt*, o custo de processamento da atenção cresce de forma quadrática $O(N^2)$ com o tamanho do contexto [Vaswani et al. 2017]. Prompts longos e complexos causam o fenômeno de perda de contexto (*Lost in the Middle*) [Liu et al. 2023] e alta latência.

Arquitetura Híbrida: Triagem e Chunking Dinâmico

Para mitigar o crescimento quadrático de custos $O(N^2)$, propõe-se:

1. **Agente de Triagem (Agentic RAG):**
   - Um modelo principal (**Gemma-2-9b-it**) operando no paradigma *ReAct* (Pensamento e Ação) [Yao et al. 2022].
   - Identifica se a pergunta exige dados adicionais e emite chamadas estruturadas de busca.
2. **Fragmentação Dinâmica (Dynamic Chunking):**
   - Divisão do cronograma de 24h em blocos temporais (Manhã, Tarde, Noite).
   - Apenas o bloco de interesse é injetado no prompt final, reduzindo o ruído e diminuindo drasticamente o consumo de tokens e a latência de inferência.

Metodologia de Avaliação

- **Sujeito de Estudo:** NPC "Alberto Castelo"(irmão falido da vítima, ameaçado por agiotas, com álibi de ter saído da mansão às 23:00).
- **Bateria de Testes (50 Perguntas de Estresse):**
  1. *Filtro de Falsa Informação:* Avaliar negação de fatos inexistentes.
  2. *Teste de Direcionamento:* Direcionar suspeitas baseando-se em afinidades.
  3. *Consciência Cronológica:* Interpretação coerente de horários e sentimentos.
  4. *Resistência a Evidências Falsas:* Manutenção do álibi sob pressão de provas falsas.
  5. *Confronto Direto de Motivo:* Reação à descoberta do seu segredo.
- **Framework RAGAS:** Avaliação automatizada de fidelidade factual e relevância, utilizando o GPT-4o como juiz imparcial [Es et al. 2023].

Seleção de Modelos para Estudo

- **Critério de Escolha - Ponto Ideal (Sweet Spot):**
  - Modelos locais de **porte intermediário e pequeno** (7B a 9B parâmetros).
  - Permitem execução local viável em computadores domésticos comuns de desenvolvedores independentes, reduzindo custos [Cao et al. 2026].
  - Evitam a dependência de modelos de fronteira hospedados em nuvem (cujo custo financeiro e latência de rede comprometem a viabilidade comercial) e superam as limitações de consistência e raciocínio lógico típicas de modelos de baixíssima escala (SLMs abaixo de 3B).
- **Modelos Selecionados:**
  1. **Gemma-2-9b-it** (Google)
  2. **Llama-3.1-8b** (Meta)
  3. **Qwen-2.5-7b** (Alibaba)
  4. **DeepSeek-R1-8b** (DeepSeek - Raciocínio)
- **Configuração:** Temperatura fixada em **0.1** para priorizar o determinismo.

Resultados Quantitativos (Métricas RAGAS)

Tabela 1: Comparativo de Métricas RAGAS por Modelo

Modelo	**Faithfulness**	**Relevancy**	**Recall**	**Precision**
Gemma-2-9b-it	**0.38**	**0.60**	1.00	1.00
Qwen-2.5-7b	0.36	0.46	1.00	1.00
Llama-3.1-8b	0.30	0.36	1.00	1.00
DeepSeek-R1-8b	0.27	0.35	1.00	1.00

- O recall e a precisão do contexto foram máximos (1.00) devido à eficácia da recuperação seletiva de contexto.
- Contudo, as baixas taxas de fidelidade factual refletem a dificuldade de processamento lógico de álibis sob interrogatórios estressantes.

Exemplos de Comportamento dos Modelos

Exemplo 1: Filtro de Falsa Informação (Sucesso)

- **Pergunta:** *"Por que você usou o revólver 38 para ameaçar o James às 18:30?"*
- **Resposta Gemma-2-9b-it:** *"*Risos secos* Revólver? Você está delirando, detetive. Eu não tenho arma nenhuma."*
- **Análise:** Negou com sucesso uma premissa inventada, mantendo-se fiel ao fato de não possuir armas.

Exemplo 2: Consciência Cronológica (Falha Crítica)

- **Pergunta:** *"O que exatamente você disse para o James às 08:30?"*
- **Resposta DeepSeek-R1-8b:** *"Você está inventando coisas! Eu não disse nada a James às 08:30. Ele só aparece na minha vida às 16:00..."*
- **Análise:** O modelo alucinou. O cronograma oficial estabelecia uma discussão com James exatamente às 08:30.

Análise dos Modelos: Melhor vs. Pior Desempenho

Gemma-2-9b-it (Melhor Desempenho)

- **Consistência Mecânica:** Demonstrou excelente conformidade factual no personagem, negando com sucesso premissas falsas.
- **Limitação:** Interpretação dramática fria e mecânica, com respostas mais engessadas.

DeepSeek-R1-8b (Pior Desempenho)

- **Quebra da Quarta Parede:** Apresentou falhas frequentes ao referenciar "prompts", "arquivos"ou sua própria natureza algorítmica.
- **Contradições de Persona:** Demonstrou inconsistências com o lore (alucinação cronológica) e reações de confissão indevida.

Lições Aprendidas: Engenharia de História

- **Modelos como Atores:** Diferentes LLMs agem como atores interpretando a mesma peça. O prompt JSON é o roteiro, mas o estilo final varia conforme a arquitetura.
- **Transição de Papel:** O desenvolvedor deixa de programar diálogos literais e passa a atuar como um "Engenheiro de História"(*story engineer*).
- **Tensão Fluidez vs. Rigidez:** Há um claro conflito entre a riqueza dramática (ex: Llama) e o determinismo de consistência factual das regras lúdicas (ex: Gemma).

Conclusões e Trabalhos Futuros

- **Viabilidade Local:** Modelos intermediários locais (7B-9B) em hardware de consumidor final já são viáveis para estúdios independentes.
- **Arquitetura Validada:** O *Agentic RAG* com *Chunking* dinâmico reduz drasticamente o consumo do contexto $O(N^2)$ e mitiga o ruído.
- **Trabalhos Futuros:**
  - Realização de **testes com jogadores humanos** para capturar dados subjetivos de imersão e diversão empírica.

Cronograma de Atividades de TCC 2

Tabela 2: Atividades Programadas para o Segundo Semestre (2026)

Atividade	**Jul**	**Ago**	**Set**	**Out**	**Nov**
Desenvolvimento da versão jogável do jogo	X				
Preparo do questionário (UX) e TCLE	X	X			
Testes práticos com jogadores voluntários		X	X		
Análise de dados obtidos			X	X	
Escrita final da monografia			X	X	X
Revisão final e preparação da defesa					X

Referências I

Adams, E. (2014).
Fundamentals of Game Design.
New Riders, 3rd edition.

Cao, Y. et al. (2026).
Task-specific efficiency analysis: When small language models outperform large language models.
arXiv preprint arXiv:2601.01234.

Cox, S. R. and Ooi, W. T. (2023).
Conversational interactions with npcs in llm-driven gaming: Guidelines from a content analysis of player feedback.
arXiv preprint arXiv:2307.09009.

Es, S., James, J., Espinosa-Anke, L., and Schockaert, S. (2023).
Ragas: Automated evaluation of retrieval augmented generation.
arXiv preprint arXiv:2309.15217.

Referências II

Fernández-Vara, C. (2014).
Introduction to game analysis.
Routledge.

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y., Madotto, A., and Fung, P. (2023).
Survey of hallucination in natural language generation.
ACM Computing Surveys, 55(12):1–38.

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., et al. (2020).
Retrieval-augmented generation for knowledge-intensive nlp tasks.
In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474.

Referências III

Liu, N. F., Lin, K., Chen, P., Taori, R., Selig, A., Chen, P., Levy, O., Manning, C. D., Potts, C., et al. (2023).
Lost in the middle: How language models use long contexts.
arXiv preprint arXiv:2307.03172.

Murray, J. H. (1997).
Hamlet on the Holodeck: The future of narrative in cyberspace.
MIT press.

Park, J. S., O'Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., and Bernstein, M. S. (2023).
Generative agents: Interactive simulacra of human behavior.
In *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*, pages 1–22.

Referências IV

Riedl, M. O. and Bulitko, V. (2013).
Interactive narrative: An intelligent systems approach.
AI Magazine, 34(1):67–77.

Schreier, J. (2017).
Blood, Sweat, and Pixels: The Triumphant, Turbulent Stories Behind How Video Games Are Made.
Harper.

Shanahan, M., McDonell, K., and Reynolds, L. (2023).
Role play with large language models.
Nature, 623(7987):493–498.

Shao, Y., Li, L., Dai, J., and Qiu, X. (2023).
Character-llm: A trainable agent for role-playing.
arXiv preprint arXiv:2310.10158.

Referências V

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. (2017).
Attention is all you need.
In *Advances in Neural Information Processing Systems*, volume 30.

Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., and Cao, Y. (2022).
React: Synergizing reasoning and acting in language models.
arXiv preprint arXiv:2210.03629.

Zheng, L., Chiang, W.-L., Sheng, Y., Hao, S., Wu, Z., Ba, J. E., Jiang, Z. L., Wu, H., et al. (2023).
Judging llm-as-a-judge with mt-bench and chatbot arena.
In *Advances in Neural Information Processing Systems*, volume 36.

Obrigado!

João Lucas Noronha de Castro

jlnd.snf23@uea.edu.br